



A Multivariate Statistical Framework for Behavioral Segmentation of Corporate Clients in the FX Market Microstructure

Corporate FX Sales & Solutions · Markets · Citibank Colombia S.A.

Jose Miguel León Puentes

Departamento de Estadística
Facultad de Ciencias
Universidad Nacional de Colombia

Oscar Orlando Melo Martínez

Departamento de Estadística
Facultad de Ciencias
Universidad Nacional de Colombia



Trabajo de Grado | Modalidad: Pasantía | Pregrado en Estadística

Inspirado en un aporte al área de Sales & Trading de FX en la mesa de dinero de Citibank. Se declara el estricto respeto de la confidencialidad, reserva y propiedad intelectual de la institución; ningún dato, análisis o conclusión aquí expuesto compromete su información ni sus intereses.

Abstract Las mesas de cambios corporativas generan datos ricos en comportamiento de cliente que rara vez se traducen en segmentación basada en evidencia. Ante la confidencialidad de los datos reales, este trabajo construye un Proceso Generador de Datos (DGP) jerárquico que reproduce con fidelidad la microestructura del mercado FX institucional colombiano —colas pesadas, inflación de ceros, economías de escala— y aplica un pipeline de reducción dimensional (PCA) y **agrupamiento no supervisado** sobre 500 clientes corporativos. La solución final de dos segmentos fue validada externamente contra la estructura poblacional del DGP, alcanzando un Índice de Rand Ajustado de 0.9722.

Keywords: Mercados de Divisas, Proceso Generador de Datos, Análisis Multivariado, Reducción de Dimensionalidad, Agrupamiento No Supervisado, Segmentación de Clientes Corporativos

Introduction La segmentación de clientes en banca cambiaria corporativa suele apoyarse en volumen nominal o en la intuición comercial, no en evidencia estadística formal. Esta brecha se agrava porque los datos transaccionales reales son un activo confidencial: no existen bases públicas para desarrollar y validar metodologías. Este trabajo aborda ambos problemas mediante simulación jerárquica condicional y un pipeline analítico reproducible.

Objectives

- General:** Desarrollar un pipeline multivariado para segmentar conductualmente clientes corporativos de una mesa FX, a partir de un DGP que replica su microestructura de mercado.
- Specific:**
 - Diseñar un DGP jerárquico de tres niveles con hechos estilizados del mercado FX colombiano.
 - Reducir el espacio de variables mediante PCA y determinar el agrupamiento óptimo por validación empírica multi-criterio.
 - Caracterizar los segmentos y validarlos externamente contra la estructura poblacional conocida del DGP.

Methodology



1. DGP Jerárquico (3 niveles)

500 clientes → 34,936 transacciones



2. Ingeniería de Características

31 → 14 variables independientes



3. PCA (Análisis de Componentes Principales)

KMO = 0.716 · 69.46% var. explicada



4. Clustering (4 algoritmos) + DBSCAN

K-Means, Ward, Hibrido, PAM



5. Validación

ARI = 0.9722




Fig. 1. Bimodalidad del volumen transaccional.

Mapa de Cargas Factoriales (Loadings)

Contribución y direccionalidad de las características conductuales en los componentes retenidos




Fig. 2. Heatmap PCA Loadings.




Fig. 3. Convergencia de criterios de validación en k=2.




Fig. 4. Separación geométrica de los segmentos (t-SNE).

Results

- Solución final: 2 segmentos analizados en profundidad mediante criterios estadísticos robustos, tras excluir 5 outliers de densidad confirmados por DBSCAN.

	Corporate (19.6%)	Transactional (80.4%)
Volumen mediano	USD 363.9M	USD 4.7M
Spread mediano	47.0 bps	161.5 bps
Desvío vs. benchmark	1.00 bps	29.89 bps
Recencia mediana	0.62 días	5.57 días
Canal / Producto / Divisas	Sin diferencia significativa (ambos)	

- Economías de escala confirmadas: $\hat{\beta} = 0.6506$, $R^2 = 92.23\%$ — el ingreso crece más lento que el volumen transado.
- Concentración de portafolio: Gini=0.81 en volumen, Gini=0.64 en ingresos.
- 16 de 20 variables de perfilamiento difieren significativamente entre segmentos (Mann-Whitney U, corrección de Bonferroni).

Key Finding

Dos segmentos, validación casi perfecta

ARI = 0.9722 frente a la estructura poblacional real del DGP.

Silueta = 0.526 · Varianza explicada = 69.46% (4 componentes).

La segmentación no refleja diferencias en qué opera el cliente (canal, producto, divisa), sino en cuánto, con qué frecuencia y con qué consistencia opera.

Discussion

- Precio:** Corporate opera casi sin desviación del benchmark (1 bps); Transaccional paga 30 bps de sobreprecio — espacio de pricing diferenciado.
- Digitalización:** Transversal (80% en ambos segmentos) — la inversión debe orientarse a inteligencia de precio en tiempo real, no a adopción de canal.
- Heterogeneidad interna:** el segmento Transactional muestra sub-estructura latente (Hopkins=0.802) — agenda abierta para sub-segmentación conductual futura.

Conclusions

- El pipeline recuperó la estructura poblacional verdadera sin acceso a etiquetas de arquetipo durante el modelado.
- La depuración de dependencias algebraicas (31→14 variables) fue condición necesaria para la validez del PCA (KMO 0.716 vs. ≤ 0.62 sin depurar).
- Limitación:** el DGP indexó la heterogeneidad conductual principalmente al tamaño del cliente; ejes de comportamiento independientes de la escala quedan como línea de investigación futura.

Additional Contributions

- Modelación a Nivel Transaccional:
 - Modelación del Revenue: Two-Part Model
 - Modelación del Spread: OLS Log-Log
 - Modelación de la Frecuencia de la Operación: Negative Binomial
- Flow Matching Live Tool: Scores Sell/Buy USD Candidate
- Dashboard Integration

Project Repository & References



Scan to access code, data, and full reference list.