




A Multivariate Statistical Framework for Behavioral Segmentation of Corporate Clients in the FX Market Microstructure

Jose Miguel León Puentes

Facultad de Ciencias
Departamento de Estadística
Universidad Nacional de Colombia
Bogotá, Colombia
2026

A Multivariate Statistical Framework for Behavioral Segmentation of Corporate Clients in the FX Market Microstructure

Jose Miguel León Puentes

Trabajo de grado presentado como requisito parcial para optar por el título de:

Estadístico

Director:

Ph.D. Oscar Orlando Melo Martínez
Profesor Titular - Departamento de Estadística
Facultad de Ciencias
Universidad Nacional de Colombia

Facultad de Ciencias
Departamento de Estadística
Universidad Nacional de Colombia
Bogotá, Colombia
2026

A Josefina y Fabio.

“Hay que tener grandeza para tolerar la injusticia de un resultado: todo se equilibra al final. Pues el error y la derrota, bien conducidos, son un camino formativo que presagia el éxito de los que jamás dejan de luchar.” Marcelo Bielsa.

Declaración

Me permito afirmar que he realizado ésta tesis de manera autónoma y con la única ayuda de los medios permitidos y no diferentes a los mencionados el presente texto. Todos los pasajes que se han tomado de manera textual o figurativa de textos publicados y no publicados, los he reconocido en el presente trabajo. Ninguna parte del presente trabajo se ha empleado en ningún otro tipo de tesis.

Asimismo, declaro que en el desarrollo de esta investigación se han respetado rigurosamente los principios de confidencialidad, reserva y privacidad de la información. Ninguno de los datos, análisis o conclusiones expuestos pone en riesgo la seguridad, integridad, propiedad intelectual o los intereses de ninguna organización, habiéndose guardado el debido respeto por el trabajo preexistente y el entorno institucional que sirvió de base e inspiración para este documento.

Bogotá, 30 de junio del 2026

A handwritten signature in black ink, appearing to read 'Leoné', enclosed within a light gray rectangular border.

Jose Miguel Leon Puentes

Agradecimientos

A Fabio, la luz de mi alma. La sensibilidad por la belleza en cada acto y mi trabajo siempre llevarán tu firma.

A mi Tatita, la vida de mi corazón. Tu devoción y cuidado formaron mis cualidades. Es a través de tus ojos que veo lo trascendental de la vida y aprendo del don de la paciencia y del servicio.

A María, por dedicarme su vida y cantar el poema que guía mis instintos. Por sus sacrificios que son inversiones y por darme los colores de esperanza con los que escribo mi vida. Soy tan solo un ejemplo de tus múltiples logros.

A Carlos, por ser ejemplo de lo que representa la responsabilidad social de enseñar. Por inculcar en mí la divulgación, la persistencia y la poesía.

A Nicolás, por invitarme a cuestionar mi rol en la industria bancaria y presentarme a Gary Stevenson.

A Carlos y Angela, por su aliento, estima y atención. Por hacerme sentir bienvenido siempre.

A Laura, por su compañía, su paciencia, por reírse junto a mí en la terquedad y demostrarme que es una digna copa que basta llenar, con compasión y ternura, sin miedo a derramar.

Al Profesor Oscar, por su paciencia y confianza en el desarrollo de este trabajo. Por ser inspiración en la incertidumbre del devenir.

A mis amigos, por siempre tener motivos por los cuales invitar a bailar al corazón y la razón. Por ser oxígeno al final del día.

A Johann, Santiago y Juan David, por su disposición a explicar, hacerme participe de la élite y ser la cara amable en la mesa.

A María Teresa, por retarme a buscar la perfección, poner a prueba la seguridad y confianza que tengo en mí y en mi trabajo.

A mi Alma Máter, por darme el espacio para explorar el ser, el amor y el conocimiento con profunda y desmedida pasión.

Resumen

Esta tesis presenta un marco cuantitativo integral para la segmentación analítica de clientes corporativos de una mesa de cambios institucional, inspirado en las dinámicas operativas del mercado de divisas colombiano. Con el fin de preservar la confidencialidad de los datos operativos garantizando simultáneamente la validez empírica, se establece un riguroso Proceso Generador de Datos (DGP) mediante simulación jerárquica condicional en tres niveles, reproduciendo los hechos estilizados del mercado cambiario institucional: distribuciones de cola pesada, inflación de ceros en spreads comerciales y heterogeneidad conductual entre arquetipos de cliente. Esta base sustenta un pipeline analítico que abarca desde el análisis exploratorio diagnóstico —incluyendo la validación de economías de escala ($\hat{\beta}_1 = 0.6506$, $R^2 = 92.23\%$) y la cuantificación de concentración mediante coeficientes de Gini (volumen: 0.81; ingresos: 0.64)— hasta técnicas multivariadas avanzadas de reducción de dimensionalidad y agrupamiento no supervisado. Un protocolo riguroso de ingeniería de características neutraliza dependencias algebraicas exactas inherentes a los pipelines de agregación contable, reduciendo el espacio de variables a 14 dimensiones genuinamente independientes sobre las cuales se aplica Análisis de Componentes Principales ($KMO = 0.716$; cuatro componentes, varianza acumulada: 69.46%). La comparación empírica de cuatro rutas de agrupamiento y cuatro algoritmos de partición, complementada por un protocolo de diagnóstico de valores atípicos mediante DBSCAN, determinó una solución final de dos segmentos con convergencia unánime de seis criterios de validación. La validación externa frente a la estructura poblacional verdadera del DGP arrojó un Índice de Rand Ajustado de 0.9722, evidenciando que el pipeline recuperó la segmentación subyacente sin acceso a las etiquetas de arquetipo. Los segmentos resultantes —*Corporate* ($n = 97$, 19.6%) y *Transactional* ($n = 398$, 80.4%)— difieren contundentemente en escala, valor económico y consistencia operativa, siendo estadísticamente indistinguibles en canal de ejecución, instrumento y dirección del flujo cambiario, hallazgo que delimita con precisión la agenda de sub-segmentación conductual para investigación futura.

Palabras Clave: Mercados de Divisas (FX), Proceso Generador de Datos (DGP), Análisis Estadístico Multivariado, Reducción de Dimensionalidad, Agrupamiento No Supervisado, Segmentación de Clientes Corporativos.

Abstract

This thesis presents a comprehensive quantitative framework for the analytical segmentation of corporate clients of an institutional foreign exchange desk, inspired by the operational dynamics of the Colombian corporate FX market. To address data confidentiality constraints while ensuring empirical validity, a rigorous three-level hierarchical conditional Data Generation Process (DGP) is established, reproducing the stylized facts of institutional FX markets: heavy-tailed distributions, zero-inflation in commercial spreads, and behavioral heterogeneity across client archetypes. This foundation supports an analytical pipeline spanning from diagnostic exploratory data analysis — including the validation of economies of scale ($\hat{\beta}_1 = 0.6506$, $R^2 = 92.23\%$) and portfolio concentration quantified through Gini coefficients (volume: 0.81; revenue: 0.64) — to advanced multivariate techniques of dimensionality reduction and unsupervised clustering. A rigorous feature engineering protocol neutralizes exact algebraic dependencies inherent to accounting aggregation pipelines, reducing the variable space to 14 genuinely independent dimensions upon which Principal Component Analysis is applied (KMO = 0.716; four components, cumulative variance: 69.46%). The empirical comparison of four clustering routes and four partitioning algorithms, complemented by a density-based outlier diagnostic protocol (DBSCAN), determined a final two-segment solution with unanimous convergence across six validation criteria. External validation against the DGP’s known population structure yielded an Adjusted Rand Index of 0.9722, confirming that the pipeline recovered the underlying segmentation without access to archetype labels during modeling. The resulting segments — *Corporate* ($n = 97$, 19.6%) and *Transactional* ($n = 398$, 80.4%) — differ markedly in scale, economic value, and operational consistency, while remaining statistically indistinguishable in execution channel, instrument type, and FX flow direction, a finding that precisely delineates the behavioral sub-segmentation agenda for future research.

Keywords: Foreign Exchange (FX) Markets, Data Generation Process (DGP), Multivariate Statistical Analysis, Dimensionality Reduction, Unsupervised Clustering, Corporate Client Segmentation.

Índice general

Resumen	III
1. Introducción	2
2. Planteamiento del Problema	5
3. Objetivos	6
4. Marco Teórico	7
4.1. Microestructura del Mercado Cambiario Corporativo	7
4.2. Segmentación de Clientes en Contextos Financieros	9
4.3. Reducción de Dimensionalidad: Análisis de Componentes Principales	10
4.4. Agrupamiento No Supervisado y Validación	11
4.5. Simulación y Procesos Generadores de Datos en Finanzas	12
5. Metodología	14
5.1. Descripción de los datos	14
5.2. Análisis Descriptivo Exploratorio	15
5.2.1. Análisis de Microestructura y Dinámica Transaccional	16
5.2.2. Análisis Portafolio de Clientes	18
5.3. Reducción Dimensional y Determinación del Agrupamiento	22
6. Resultados	28
6.1. Análisis de Microestructura y Dinámica Transaccional	28
6.1.1. Caracterización Univariada, Colas Pesadas e Inflación de Ceros	28
6.1.2. Microeconomía del Spread: Economías de Escala, Efecto Canal/Producto	31
6.1.3. Análisis Temporal de Alta Frecuencia	33
6.1.4. Balance de Flujo, Pipeline de Divisas y Direccionalidad	34
6.2. Análisis Portafolio de Clientes	35
6.3. Reducción de Dimensionalidad	38

6.3.1.	Protocolo de Selección de Características y Prevención de Singularidad	38
6.3.2.	Adecuación Muestral para PCA	39
6.3.3.	Aplicación del Análisis de Componentes Principales	40
6.3.4.	Determinación del Número de Componentes a Retener	41
6.3.5.	Interpretación de la Estructura Latente Base	43
6.3.6.	Validación Empírica del Espacio Geométrico y Selección de Clusters .	44
6.4.	Determinación del Agrupamiento	50
6.4.1.	Perfil Descriptivo de los Segmentos	51
6.4.2.	Diagnóstico de Heterogeneidad Interna	52
7.	Conclusiones	55
7.1.	Implicaciones Gerenciales	55
7.1.1.	Estrategia de Precio y Gestión del Spread	55
7.1.2.	Estrategia de Canal y Digitalización	56
7.1.3.	Gestión de la Recencia y Prevención de Abandono	57
7.1.4.	Asignación de Capacidad Comercial	57
7.1.5.	Tratamiento del Grupo Residual de Actividad Atípica	58
7.2.	Síntesis de Hallazgos	59
7.2.1.	Contribuciones Metodológicas	59
7.2.2.	Hallazgos Estadísticos	60
7.2.3.	Hallazgos Sustantivos	61
7.3.	Limitaciones	62
7.3.1.	Limitaciones del Proceso Generador de Datos	62
7.3.2.	Limitaciones del Análisis	62
7.4.	Recomendaciones	63
8.	Apéndice	65
8.1.	Metodología de Simulación y el Proceso Generador de Datos (DGP)	65
8.2.	Diccionario de Variables	73
	Referencias	77

1. Introducción

El mercado de divisas corporativo constituye uno de los segmentos más dinámicos y operativamente exigentes dentro de la banca de inversión y tesorería institucional. En él confluyen empresas importadoras, exportadoras, estructuradoras de deuda y tesorerías multinacionales con necesidades cambiarias heterogéneas, frecuencias transaccionales dispares y sensibilidades al precio radicalmente distintas. Sin embargo, pese a la riqueza informacional que generan las operaciones diarias de una mesa de cambios —cada transacción registra el volumen, el spread cobrado, el canal de ejecución, el instrumento, la direccionalidad del flujo y la identidad de la contraparte—, esta información rara vez trasciende el plano operativo para convertirse en conocimiento estructurado sobre el cliente. La gestión comercial tiende a operar sobre la intuición del ejecutivo de ventas, sobre métricas de volumen agregado y sobre clasificaciones informales que no resisten un escrutinio estadístico formal. El resultado es una brecha persistente entre la riqueza de los datos transaccionales disponibles y la inteligencia comercial efectivamente desplegada.

Esta brecha no es accidental: responde a condicionantes estructurales del entorno en el que operan las mesas de cambios corporativas en economías emergentes. Los grandes bancos internacionales con presencia en estos mercados tienden a centralizar sus capacidades analíticas en casa matriz o en unidades regionales especializadas, reservando para las operaciones locales un rol predominantemente ejecutor. El resultado es que el conocimiento estadístico aplicado al negocio cambiario no se desarrolla localmente: los equipos comerciales locales operan sin acceso a metodologías cuantitativas avanzadas, sin infraestructura de datos estructurada para el análisis y, con frecuencia, sin el puente conceptual entre el lenguaje del negocio y el lenguaje de la estadística. A esto se suma una limitación adicional: no existen bases de datos de operaciones FX corporativas de acceso público que permitan el desarrollo y validación de metodologías fuera del entorno bancario, dado que la información transaccional es considerada activo estratégico confidencial por las instituciones que la generan.

En el ámbito académico, la estadística aplicada a los mercados financieros ha privilegiado históricamente el modelado de series de tiempo, los modelos de vectores autorregresivos (VAR), la econometría de alta frecuencia y la valoración de instrumentos derivados. Estas contribuciones son de indudable valor, pero dejan sin atender una pregunta de naturaleza

distinta y de alta relevancia práctica: ¿quiénes son los clientes de una mesa de cambios, cómo se comportan, qué los diferencia y cómo puede ese conocimiento traducirse en estrategias comerciales accionables? Este tipo de análisis —orientado al cliente, no al instrumento; al comportamiento agregado, no a la dinámica de precios— raramente aparece en la literatura especializada de microestructura de mercados cambiarios, y cuando aparece, lo hace en contextos de banca minorista o mercados desarrollados, no en el segmento corporativo institucional de economías latinoamericanas.

El presente trabajo se propone cerrar esa brecha desde una perspectiva deliberadamente pragmática. El objetivo no es aplicar metodologías complejas por su sofisticación intrínseca, sino construir un retrato cuantitativo riguroso del portafolio de clientes de una mesa de cambios corporativa: comprender su operación, identificar patrones de comportamiento, detectar agrupamientos naturales y transitar de la clasificación informal basada en la intuición comercial a una segmentación fundamentada en evidencia estadística formal. Para ello, el análisis multivariado no supervisado —en particular la reducción de dimensionalidad mediante Análisis de Componentes Principales y el agrupamiento mediante algoritmos de partición— ofrece un conjunto de herramientas metodológicamente sólido, visualmente interpretable y computacionalmente accesible, cuya parsimonia lo hace especialmente adecuado para contextos donde el valor debe ser generado con recursos de tiempo acotados y donde la interpretabilidad de los resultados es tan importante como su precisión estadística. El puente entre el negocio y la estadística no puede construirse desde un solo extremo: requiere tanto del conocimiento de la microestructura del mercado cambiario como del dominio de las herramientas cuantitativas que permiten formalizarla.

Dado que los datos transaccionales reales de operaciones FX corporativas no son de acceso público, el estudio establece un Proceso Generador de Datos (DGP) mediante simulación jerárquica condicional, diseñado para reproducir con alta fidelidad los hechos estilizados del mercado cambiario institucional colombiano: la asimetría y curtosis extremas de los volúmenes transados, la inflación de ceros en los spreads comerciales, las economías de escala en la fijación de precios y la heterogeneidad conductual entre distintos perfiles de cliente corporativo. Este enfoque permite desarrollar y validar el pipeline analítico completo sobre una base de datos con propiedades empíricas realistas, sin comprometer la confidencialidad de ninguna institución específica, y abre la posibilidad de replicar la metodología sobre datos reales en cuanto las condiciones de acceso lo permitan.

El documento se organiza de la siguiente manera. La Sección 2 formula el planteamiento del problema y delimita el alcance del estudio. La Sección 3 enuncia los objetivos general y específicos. La Sección 4 desarrolla el marco teórico que sustenta las decisiones metodológicas. La Sección 5 describe en detalle el DGP, el protocolo de ingeniería de características, el Análisis de Componentes Principales y el esquema de comparación de algoritmos de agrupamiento. La Sección 6 presenta los resultados empíricos, desde el análisis exploratorio de microestructura hasta la caracterización final de los segmentos y el diagnóstico de heterogeneidad

interna. Finalmente, la Sección 7 sintetiza los hallazgos, deriva las implicaciones gerenciales accionables, documenta las limitaciones del estudio y traza la agenda de investigación futura.

2. Planteamiento del Problema

Las mesas de cambios corporativas generan, en el curso ordinario de su operación, un volumen considerable de datos transaccionales que registran con precisión el comportamiento cambiario de cada cliente: los montos operados, los spreads pactados, los canales de ejecución, la frecuencia y la regularidad de las operaciones. Sin embargo, esta información rara vez es objeto de un análisis estadístico estructurado. La segmentación de clientes en este contexto se apoya predominantemente en criterios informales de volumen nominal o en la experiencia subjetiva del ejecutivo comercial, lo que limita la capacidad de la institución para comprender con precisión el perfil conductual de su portafolio, identificar agrupamientos naturales entre clientes y diseñar estrategias de relacionamiento diferenciadas con fundamento cuantitativo. La ausencia de metodologías analíticas aplicadas al cliente —en contraste con la abundante literatura estadística orientada al instrumento financiero o a la dinámica de precios— constituye una brecha de conocimiento con implicaciones directas sobre la gestión comercial y la captura de valor de la mesa.

A esta limitación analítica se suma la imposibilidad práctica de acceder a datos transaccionales reales de operaciones FX corporativas fuera del entorno institucional que los genera, dado su carácter estrictamente confidencial. En consecuencia, el desarrollo y validación de metodologías cuantitativas orientadas a la segmentación de clientes en este mercado requiere la construcción de una base de datos sintética que preserve las propiedades microestructurales del mercado cambiario institucional, permitiendo que los resultados del análisis sean metodológicamente transferibles a contextos operativos reales. El problema central que aborda esta investigación es, por tanto, doble: por un lado, la construcción de un proceso generador de datos que simule con fidelidad empírica la operación de una mesa de cambios corporativa; y por otro, el desarrollo de un pipeline analítico multivariado que permita construir un retrato cuantitativo riguroso del portafolio de clientes, identificar segmentos con base en su comportamiento transaccional agregado y derivar implicaciones comerciales accionables a partir de evidencia estadística formal.

3. Objetivos

Objetivo General

Desarrollar un pipeline analítico multivariado para la segmentación conductual de clientes corporativos de una mesa de cambios institucional, a partir de un proceso generador de datos que reproduce las propiedades microestructurales del mercado cambiario corporativo, con el propósito de construir un retrato cuantitativo del portafolio de clientes que traslade la clasificación comercial informal hacia una segmentación fundamentada en evidencia estadística formal.

Objetivos Específicos

1. Diseñar e implementar un Proceso Generador de Datos (DGP) mediante simulación jerárquica condicional que reproduzca los hechos estilizados del mercado cambiario corporativo colombiano —incluyendo la estructura de economías de escala, la heterogeneidad conductual entre arquetipos de cliente y las propiedades distribucionales de cola pesada— y construir sobre él un protocolo de ingeniería de características que garantice la independencia algebraica y estadística del espacio de variables empleado en el análisis multivariado.
2. Aplicar Análisis de Componentes Principales sobre el espacio de características depurado y determinar empíricamente, mediante la comparación sistemática de rutas alternativas de agrupamiento y múltiples criterios de validación interna, la especificación óptima de reducción dimensional y número de segmentos que maximice la calidad geométrica de la partición resultante.
3. Caracterizar estadísticamente los segmentos identificados mediante pruebas no paramétricas con control de error por comparaciones múltiples, cuantificar su separación inter-grupal y su heterogeneidad interna, y traducir los hallazgos en implicaciones comerciales accionables para la gestión diferenciada del portafolio de clientes de la mesa de cambios.

4. Marco Teórico

4.1. Microestructura del Mercado Cambiario Corporativo

El mercado de divisas (Foreign Exchange, FX) constituye el mercado financiero de mayor volumen de negociación a nivel global, con un promedio diario de transacciones que supera los seis billones de dólares según el Banco de Pagos Internacionales. En Colombia, la operación del mercado cambiario está regulada por el Banco de la República y la Superintendencia Financiera de Colombia, bajo el marco normativo establecido en el Estatuto Cambiario (Decreto 444 de 1967 y sus modificaciones). Los agentes autorizados para intermediar en este mercado reciben la denominación de Intermediarios del Mercado Cambiario (IMC), categoría que comprende los bancos comerciales, las corporaciones financieras y las sociedades comisionistas de bolsa autorizadas. La operación interbancaria de divisas en el segmento Spot se canaliza a través del sistema electrónico SET-FX, administrado por SET-ICAP FX S.A., que centraliza la negociación y fijación de la Tasa Representativa del Mercado (TRM) como referencia oficial del tipo de cambio USD/COP.

Dentro de este marco institucional, las mesas de cambios corporativas de los bancos comerciales operan como intermediarias entre las necesidades cambiarias de sus clientes y la liquidez disponible en los mercados interbancarios locales e internacionales. La regulación cambiaria colombiana distingue dos grandes categorías de contrapartes: los *clientes del mercado cambiario real*, que comprenden personas naturales y empresas del sector real de la economía con obligaciones o derechos en moneda extranjera derivados de operaciones de comercio exterior, inversión o endeudamiento; y los *clientes del mercado vigilado* o institucional, que incluyen otras entidades financieras, fondos de inversión y administradoras de activos. En la práctica operativa de una mesa de cambios corporativa, el portafolio de clientes abarca desde empresas importadoras y exportadoras de diversos sectores económicos, hasta subsidiarias de multinacionales, entidades del sector público —incluyendo ministerios, alcaldías, empresas industriales y comerciales del Estado como Ecopetrol, y entidades de fomento como Bancóldex— y ocasionalmente el propio Banco de la República en operaciones de intervención cambiaria.

La unidad fundamental de análisis en este contexto es la transacción individual, cuyos atributos principales son el monto en equivalencia USD (*volumen*), el instrumento negociado, el canal de ejecución, la tasa de mercado de referencia (*Market Rate*) y la tasa final pactada con el cliente (*Deal Rate*). El diferencial entre ambas tasas constituye el *spread* comercial, expresado convencionalmente en puntos básicos (basis points, BPS), donde un punto básico equivale a una centésima parte de un punto porcentual ($1\text{BPS} = 0.01\%$). Desde la perspectiva de la mesa, el *spread* se materializa como la diferencia entre el precio de compra (*bid*) y el precio de venta (*offer*) cotizado al cliente respecto a la tasa interbancaria: en una operación de venta de USD al cliente, la mesa ofrece una tasa *offer* superior a la tasa de mercado; en una operación de compra, una tasa *bid* inferior. El ingreso bruto por transacción (*USD Revenue*) se obtiene como el producto del volumen transado por el *spread* aplicado en su equivalencia monetaria.

En la práctica institucional de los grandes bancos internacionales, el concepto de valor generado por un cliente en la mesa de cambios trasciende el *spread* cobrado directamente. El ingreso total asociado a una relación de *Corporate FX Sales* se descompone típicamente en tres componentes: el *Client Value* (CV), correspondiente al valor presente del *spread* comercial cobrado al cliente; el *Net Economic Value* (NEV), bono de rentabilidad atribuido al área de ventas por haber atraído flujo de divisas que permite a la mesa gestionar su posición de inventario; y el *Flow Value* (FV), asociado al valor de las órdenes en términos de información de mercado y profundidad de libro. Esta descomposición, aunque no siempre estandarizada entre instituciones, refleja que la rentabilidad de un cliente no se agota en el margen unitario de cada transacción, sino que incorpora el valor estratégico del flujo que aporta al balance de inventario de la mesa.

Los instrumentos transados se clasifican según su plazo de liquidación. Las operaciones *Spot* corresponden a transacciones de entrega en un plazo máximo de tres días hábiles tras la fecha de negociación ($t+0$, $t+1$, $t+2$ o $t+3$), ejecutadas a la tasa vigente en el mercado interbancario. Un caso particular son las operaciones *FIX*, liquidadas al valor de la TRM oficial del día, empleadas frecuentemente por clientes con obligaciones contractuales indexadas a esta referencia. Las operaciones *Forward* son contratos de compraventa a una tasa pactada hoy para liquidación en fecha futura superior a tres días hábiles, incorporando el diferencial de tasas de interés entre divisas. Más allá de estos instrumentos de flujo recurrente, el mercado corporativo ofrece soluciones de gestión de riesgo cambiario de mayor complejidad: opciones de divisas europeas y americanas, estructuras *collar* (combinación de opciones de compra y venta que acotan el riesgo dentro de un rango), TARNs (*Target Redemption Notes*), depósitos vinculados al tipo de cambio y contratos marco ISDA que habilitan la operación de derivados OTC bajo un régimen de compensación bilateral. Estas estructuras, que requieren un perfil de cliente con mayor sofisticación financiera y capacidad legal para operar derivados, quedan fuera del alcance del presente análisis, circunscrito a las operaciones *Spot* y *Forward* que constituyen el flujo recurrente de la mesa.

Las estrategias comerciales de una mesa de cambios corporativa se articulan típicamente en tres segmentos de relacionamiento. El segmento de *Captura de Volumen* agrupa a clientes con alta frecuencia transaccional y operaciones de tamaño moderado, gestionados con énfasis

en eficiencia operativa y digitalización del canal de ejecución. El segmento de *Transacciones Estratégicas* comprende clientes con operaciones esporádicas pero de gran envergadura nominal —fusiones y adquisiciones, estructuración de deuda externa, repatriación de utilidades de subsidiarias multinacionales— que requieren preparación anticipada, negociación de precio institucional y coordinación con la posición de inventario de la mesa. El segmento de *Coberturas y Derivados* corresponde a los clientes de mayor sofisticación, que demandan estructuras de cobertura cambiaria a medida bajo contrato marco ISDA, con interacción frecuente entre el ejecutivo de ventas, el área de estructuración y la tesorería del cliente. A estos se suma el segmento de *Soluciones Digitales*, orientado a clientes que ejecutan la totalidad de sus operaciones a través de plataformas electrónicas propias del banco o multibancarias —como Bloomberg FXGO o Deutsche Börse 360T— y cuya interacción con el ejecutivo comercial es mínima, inexistente o complementa otros servicios adquiridos con el banco.

La heterogeneidad multidimensional del portafolio de clientes que emerge de esta estructura —en términos de volumen, frecuencia, sensibilidad al precio, sofisticación del instrumento, canal de ejecución y tipo de relación comercial— justifica la adopción de un enfoque de segmentación conductual basado en el comportamiento transaccional agregado del cliente, en lugar de clasificaciones univariadas por volumen nominal. Comprender quiénes son los clientes, cómo operan y qué los diferencia constituye el punto de partida para diseñar estrategias de relacionamiento con fundamento cuantitativo, capturar de forma más eficiente la participación de mercado (*market share*) de cada cliente y asignar la capacidad comercial de la mesa en función de la rentabilidad esperada de cada segmento.

4.2. Segmentación de Clientes en Contextos Financieros

La segmentación de clientes constituye una de las aplicaciones más directas y de mayor impacto práctico del análisis estadístico multivariado en el ámbito comercial y financiero. En su formulación más general, el problema de segmentación consiste en identificar subgrupos de clientes que sean internamente homogéneos en sus características de comportamiento y externamente heterogéneos entre sí, con el propósito de diseñar estrategias de relacionamiento diferenciadas que maximicen la captura de valor para la institución (Hair et al., 2019). En el contexto de la banca corporativa, esta tarea adquiere una dimensión adicional de complejidad: el comportamiento del cliente no se expresa en una única variable observable, sino en un conjunto multidimensional de indicadores que capturan simultáneamente su escala económica, su regularidad operativa, su sensibilidad al precio, su fidelidad institucional y su perfil de riesgo cambiario.

La literatura de gestión de clientes en servicios financieros ha transitado progresivamente desde clasificaciones univariadas basadas en el volumen nominal —que capturan la dimensión

de tamaño pero ignoran la heterogeneidad conductual dentro de cada estrato de volumen— hacia marcos multidimensionales que integran métricas de rentabilidad, recurrencia y valor proyectado. En esta dirección, el concepto de *Customer Lifetime Value* (CLV) ha ganado centralidad como indicador sintético del valor económico de un cliente para la institución a lo largo del tiempo, incorporando la dimensión temporal mediante factores de descuento por inactividad y primas por comportamientos que reducen el costo de servicio (Kumar, 2008). En el mercado cambiario corporativo, la estimación del CLV enfrenta el desafío adicional de que el valor del cliente no se agota en el spread cobrado por transacción, sino que incorpora el valor del flujo aportado a la posición de inventario de la mesa y la información de mercado implícita en sus órdenes. La variable *Share of Wallet* —definida como la proporción del volumen cambiario total del cliente que es capturada por una institución específica frente al total operado en el mercado— complementa al CLV como indicador de la profundidad de la relación comercial y del potencial de crecimiento dentro de cada cuenta.

La distinción metodológica entre variables de partición y variables de descripción es particularmente relevante en este contexto (Hair et al., 2019). Las variables de partición son aquellas empleadas directamente en el algoritmo de agrupamiento y deben satisfacer requisitos de independencia estadística y no redundancia algebraica; las variables de descripción son aquellas que, una vez obtenida la partición, se emplean para caracterizar e interpretar los segmentos en el lenguaje operativo del negocio. Esta distinción no es meramente formal: la inclusión de variables algebraicamente dependientes en el espacio de partición distorsiona la geometría del agrupamiento y puede inducir segmentos espurios que reflejan identidades contables antes que estructuras de comportamiento genuinas.

4.3. Reducción de Dimensionalidad: Análisis de Componentes Principales

El Análisis de Componentes Principales (PCA, por sus siglas en inglés) es una técnica de reducción de dimensionalidad que proyecta un conjunto de variables originales correlacionadas en un nuevo sistema de coordenadas ortogonales —los componentes principales— ordenados de mayor a menor varianza explicada (Jolliffe, 2002). Formalmente, dado un conjunto de p variables estandarizadas organizadas en la matriz $\mathbf{X}_{n \times p}$, el PCA obtiene la descomposición espectral de la matriz de correlación $\mathbf{R} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^\top$, donde $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$ contiene los autovalores ordenados de forma decreciente y las columnas de $\mathbf{V}$ contienen los autovectores asociados (cargas factoriales). Los scores de los componentes principales se obtienen como $\mathbf{Z} = \mathbf{X}\mathbf{V}$, y cada componente j explica una proporción λ_j/p de la varianza total del sistema.

La determinación del número de componentes a retener constituye una decisión metodológica central que la literatura aborda mediante criterios no necesariamente convergentes (Johnson & Wichern, 2007; Jolliffe, 2002). El criterio de Kaiser retiene aquellos componentes cuyo autovalor supera la unidad, bajo el argumento de que un componente con $\lambda < 1$ explica

menos varianza que una única variable original estandarizada (Kaiser, 1960). El examen visual del gráfico de sedimentación (*scree plot*) busca el punto de inflexión en la pendiente de los autovalores, privilegiando la parsimonia sobre la completitud (Cattell, 1966). La regla de varianza acumulada establece umbrales de referencia —típicamente entre el 70 % y el 80 % para aplicaciones en ciencias sociales y de negocios— como criterio de suficiencia informacional (Hair et al., 2019). Ante la divergencia entre estos criterios, la práctica recomendada consiste en su aplicación conjunta y en la validación empírica de distintas especificaciones en la etapa de modelado subsiguiente, antes de fijar una única solución a priori.

La pertinencia estadística de aplicar PCA sobre un conjunto de variables se evalúa mediante dos pruebas complementarias. La prueba de esfericidad de Bartlett contrasta la hipótesis nula de que la matriz de correlación es estadísticamente equivalente a una matriz identidad, condición bajo la cual ningún método de reducción dimensional basado en correlaciones compartidas resultaría informativo. El índice de adecuación muestral de Kaiser-Meyer-Olkin (KMO) cuantifica la proporción de varianza atribuible a factores comunes frente a varianza idiosincrática, con valores superiores a 0.70 considerados adecuados para la extracción de componentes (Kaiser, 1974).

Cuando el PCA se emplea como insumo geométrico para un algoritmo de agrupamiento no supervisado —y no como técnica de interpretación factorial autónoma—, la selección del número de componentes a retener debe considerar adicionalmente que dimensiones de varianza moderada pueden ser críticas para la separación geométrica de subgrupos genuinos, aunque no sean dominantes en términos de varianza total explicada (Ding & He, 2004; Yeung & Ruzzo, 2001). Esta propiedad justifica la evaluación empírica de múltiples especificaciones de retención antes de fijar el espacio de agrupamiento.

4.4. Agrupamiento No Supervisado y Validación

El agrupamiento no supervisado (*clustering*) tiene por objetivo identificar una partición de n observaciones en k grupos que maximice la homogeneidad intra-grupo y la heterogeneidad inter-grupo, sin recurrir a etiquetas de clase predefinidas (Johnson & Wichern, 2007). En el presente trabajo se evalúan cuatro algoritmos con fundamentos matemáticos distintos, cuya comparación permite identificar estructuras de agrupamiento robustas a la elección del método.

El algoritmo *K-Means* (Lloyd, 1982; MacQueen, 1967) minimiza la suma de cuadrados intra-cluster mediante la actualización iterativa de centroides, asignando cada observación al centroide más cercano en términos de distancia euclidiana. Su sensibilidad a la inicialización se mitiga mediante múltiples reinicios aleatorios. El *clustering jerárquico aglomerativo* bajo el criterio de Ward (Murtagh & Legendre, 2014; Ward, 1963) construye una jerarquía de fusiones minimizando el incremento en la suma de cuadrados intra-grupo en cada paso, produciendo un dendrograma cuya estructura permite identificar el número de grupos

asociado al mayor salto de altura entre fusiones consecutivas. El *método híbrido* (Milligan, 1980; Punj & Stewart, 1983) emplea los centroides del corte del dendrograma de Ward como inicialización determinística de K-Means, combinando la robustez estructural del método jerárquico con la capacidad de refinamiento local del algoritmo de partición. El *Partitioning Around Medoids* (PAM) (Kaufman & Rousseeuw, 1990) sustituye los centroides por medoides —observaciones reales del conjunto de datos— y minimiza distancias absolutas en lugar de distancias al cuadrado, confiriéndole una resistencia sustancialmente mayor a la influencia de valores atípicos respecto a los tres métodos anteriores.

La calidad de una solución de agrupamiento se evalúa mediante índices de validación interna que no requieren conocimiento externo de la estructura verdadera. El *coeficiente de silueta* (Rousseeuw, 1987) cuantifica, para cada observación, la cohesión intra-cluster relativa a la separación respecto al cluster vecino más próximo, con valores en el intervalo $[-1, 1]$ donde valores superiores a 0.50 indican una estructura bien definida. El *índice de Calinski-Harabasz* (Caliński & Harabasz, 1974) se define como la razón entre la dispersión inter-cluster y la dispersión intra-cluster ponderada por los grados de libertad correspondientes, con valores mayores indicando mejor separación. El *índice de Davies-Bouldin* (Davies & Bouldin, 1979) mide la similitud promedio entre cada cluster y su vecino más cercano, donde valores menores indican mayor separación. El procedimiento de votación implementado en el paquete **NbClust** (Charrad et al., 2014) integra simultáneamente hasta veintiséis índices de validación y determina el número óptimo de clusters mediante regla de mayoría, constituyendo una verificación robusta e independiente de los índices individuales.

Cuando existe discrepancia entre los resultados de algoritmos sensibles a valores atípicos (K-Means, Ward) y algoritmos robustos (PAM), dicha discrepancia constituye evidencia diagnóstica de la posible influencia de observaciones extremas sobre la solución de agrupamiento (Kaufman & Rousseeuw, 1990; Milligan, 1980). El algoritmo DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) (Ester et al., 1996) permite formalizar este diagnóstico: clasifica como ruido aquellas observaciones que no pertenecen a ninguna región de densidad suficiente, proporcionando una identificación no paramétrica de valores atípicos en el espacio de características. La validación externa de la solución final se realiza mediante el *Índice de Rand Ajustado* (ARI) (Hubert & Arabie, 1985), que cuantifica la concordancia entre la partición obtenida y una estructura de referencia conocida, corrigiendo por la concordancia esperada bajo asignación aleatoria, con valores en el intervalo $[-1, 1]$ donde 1 indica concordancia perfecta.

4.5. Simulación y Procesos Generadores de Datos en Finanzas

La indisponibilidad de datos transaccionales reales para el desarrollo y validación de metodologías analíticas en el mercado cambiario corporativo responde a una restricción estructural

del sector financiero: la información transaccional de clientes constituye un activo estratégico confidencial cuya divulgación está sujeta a restricciones regulatorias y contractuales estrictas. En este contexto, la simulación estocástica mediante procesos generadores de datos (DGP) se consolida como una alternativa metodológicamente válida, en tanto permite construir bases de datos con propiedades distribucionales y relacionales predeterminadas que reproducen los hechos estilizados del fenómeno de interés (Cont, 2001).

Un proceso generador de datos sintético se distingue de una simulación de Monte Carlo genérica en que su diseño está explícitamente orientado a reproducir la estructura multivariada del fenómeno real: las distribuciones marginales de cada variable, las dependencias entre variables, las reglas de negocio que gobiernan las relaciones entre entidades y los mecanismos causales subyacentes. La simulación jerárquica condicional —en la que cada nivel de granularidad se genera condicionado a los parámetros del nivel superior— es la estrategia más adecuada para fenómenos con estructura anidada, como el caso de transacciones individuales condicionadas a los atributos latentes de cada cliente (Johnson & Wichern, 2007). Esta arquitectura garantiza que las dependencias observadas en los datos sintéticos reflejen mecanismos económicos plausibles y no correlaciones espurias inducidas por el proceso de generación.

La validez de un DGP se evalúa mediante el contraste entre las propiedades estadísticas de los datos sintéticos y los hechos estilizados documentados en la literatura empírica del fenómeno modelado (Cont, 2001): la forma distribucional de las variables clave, los parámetros de concentración y desigualdad, los patrones de correlación entre variables y la reproducción de regularidades conocidas como las economías de escala en la fijación de precios cambiarios. Una ventaja adicional del enfoque de simulación en el contexto del presente trabajo es que la estructura poblacional verdadera —los arquetipos de cliente y sus parámetros— es conocida a priori, lo que permite una validación externa de la solución de agrupamiento mediante el contraste directo entre la partición obtenida algorítmicamente y la pertenencia real de cada observación a su arquetipo de origen, modalidad de validación no disponible en el análisis de datos observacionales convencional.

5. Metodología

5.1. Descripción de los datos

Information about money is almost as important as money itself.

Walter B. Wriston, 1992.

La información empleada en este estudio proviene de dos bases de datos sintéticas generadas mediante un Proceso Generador de Datos (DGP) diseñado para reproducir las características operativas y comerciales del mercado de compra y venta de divisas para clientes corporativos. El esquema de simulación se desarrolló con el propósito de preservar las relaciones multivariadas observadas en este tipo de negocios, incorporando simultáneamente variables continuas, categóricas y temporales, así como estructuras de dependencia entre clientes y transacciones.

El DGP se implementó bajo una estrategia de simulación jerárquica condicional compuesta por tres niveles. En primer lugar, se generó una población de 500 clientes corporativos con características latentes diferenciadas. Posteriormente, se simuló un portafolio de operaciones cambiarias condicionado a los atributos de cada cliente, obteniendo un total de 34 936 transacciones registradas entre enero y diciembre de 2025. Finalmente, la información transaccional fue agregada a nivel de cliente para construir un conjunto de indicadores comerciales y métricas de comportamiento.

Las bases de datos resultantes son las siguientes:

- **Base Transaccional:** contiene el registro individual de cada operación de compra o venta de divisas. Incluye información de identificación, temporalidad, características del producto negociado, volumen operado, ingresos generados y variables asociadas a la estructura cambiaria de la transacción. La base está conformada por 34 936 obser-

vaciones y 17 variables.

- **Base Clientes:** corresponde a una visión consolidada de los clientes corporativos, construida mediante la agregación de la información transaccional. Contiene indicadores de actividad, rentabilidad, recurrencia, comportamiento operativo y métricas analíticas orientadas a la caracterización comercial de cada cliente. Esta base está conformada por 500 clientes y 26 variables.

Ninguna de las dos bases de datos presenta valores faltantes. El procedimiento completo de simulación puede consultarse en el Apéndice 8.1, donde se describe detalladamente la metodología de simulación y el Proceso Generador de Datos (DGP). De igual forma, la definición exhaustiva de cada variable se encuentra disponible en el Apéndice 8.2, correspondiente al diccionario de variables.

Las Tablas 5.1 y 5.2 presentan un resumen de las principales variables consideradas en cada una de las bases de datos.

<i>Categoría</i>	Variables	Cantidad
<i>Identificación</i>	Deal_Number, Client_ID, Client_Name, Sales_ID	4
<i>Temporalidad</i>	Deal_Date, Settlement_Lag	2
<i>Canal y producto</i>	Channel, Product	2
<i>Volumen e ingresos</i>	USD_Volume, USD_Revenue	2
<i>Precios y rentabilidad</i>	Spread_BPS, Market_Rate, Deal_Rate	3
<i>Información cambiaria</i>	Buy_CCY, Sell_CCY, Currency_Pair, Flow_Direction	4

Cuadro 5.1: Estructura temática de las variables de la base transaccional.

5.2. Análisis Descriptivo Exploratorio

Exploratory data analysis can never be the whole story, but nothing else can serve as the foundation stone.

John W. Tukey, 1977.

El análisis descriptivo exploratorio de datos en esta investigación se concibe como el protocolo formal de validación de los hechos estilizados (*stylized facts*) subyacentes a la microestructura del mercado cambiario corporativo (Cont, 2001). Esta fase constituye el fundamento

<i>Categoría</i>	Variables	Cantidad
<i>Identificación</i>	Client_ID, Client_Name, Sales_ID	3
<i>Actividad transaccional</i>	Count_of_Deals, Active_Days, Ultima_Trx, Recency_Days	4
<i>Volumen e ingresos</i>	Bank_Volume, Total_Revenue, Average_Deal_Size, Average_Revenue	4
<i>Condiciones comerciales</i>	Average_Spread_BPS, Spread_Price_Sensitivity, Spread_vs_Benchmark	3
<i>Composición del portafolio</i>	Porcentaje_Spot, Porcentaje_Digital, Porcentaje_COP	3
<i>Direccionalidad cambiaria</i>	Pct_Buy_USD, Pct_Sell_USD, USD_Flow_Direction	3
<i>Participación y contribución</i>	Revenue_Share_Pct	1
<i>Analítica de clientes</i>	CLV_Proxy, sow_score, Share_of_Wallet, Total_Wallet	4

Cuadro 5.2: Estructura temática de las variables de la base de clientes.

empírico indispensable para verificar las hipótesis estructurales del Proceso Generador de Datos (DGP) antes de proceder a las etapas de inferencia y modelado.

Cabe aclarar que, dada la naturaleza controlada de la simulación base, el flujo prescinde de una etapa tradicional de imputación de datos faltantes o limpieza de datos. No obstante, eventualmente se incorpora un riguroso tratamiento de valores atípicos e identificación de puntos de apalancamiento mediante distancias estadísticas robustas.

5.2.1. Análisis de Microestructura y Dinámica Transaccional

Esta dimensión metodológica aborda el comportamiento de alta frecuencia a nivel operativo en la base transaccional, analizando las propiedades asintóticas de las variables continuas, la teoría de la firma aplicada a las economías de escala y los patrones de concentración temporal.

Caracterización Univariada, Colas Pesadas e Inflación de Ceros

Se examinan las propiedades distributivas de las variables continuas clave: Volumen en equivalencia USD (V_{ij}), Ingreso (R_{ij}) y Spread en puntos básicos (S_{ij}). Para caracterizar el apartamiento de la normalidad y la presencia de colas pesadas (*heavy tails*), se estiman el

coeficiente de asimetría de Fisher (γ_1) y la curtosis de exceso (γ_2):

$$\gamma_1 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right], \quad \gamma_2 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] - 3$$

Con el propósito de evaluar la hipótesis de lognormalidad en los volúmenes transados ($V_{ij} \sim \text{Lognormal}(\mu, \sigma^2)$), se implementan las pruebas de bondad de ajuste de Kolmogorov-Smirnov (D) con la corrección de Lilliefors y la prueba de Anderson-Darling (A^2), esta última seleccionada por su sensibilidad superior en las colas de la distribución. El estadístico A^2 se define como:

$$A^2 = -n - \sum_{k=1}^n \frac{2k-1}{n} \left[\ln F_0(Y_{(k)}) + \ln (1 - F_0(Y_{(n-k+1)})) \right]$$

Donde $Y_{(k)} = \ln(V_{(k)})$ representa el estadístico de orden k -ésimo y F_0 es la función de distribución acumulada normal teórica.

Frente al fenómeno de inflación de ceros en los spreads comerciales, se cuantifica la masa de probabilidad exacta en el origen $P(S_{ij} = 0)$. Se evalúa la dependencia condicional de esta probabilidad respecto a variables categóricas como el Canal ($Channel_{ij}$) y el Producto ($Product_{ij}$) mediante pruebas de independencia de χ^2 de Pearson sobre tablas de contingencia.

Microeconomía del Spread: Economías de Escala y Efecto Canal-Producto

Para evaluar la hipótesis microeconómica de rendimientos decrecientes en el cobro del margen (economías de escala a favor del cliente de alto volumen), se analiza la elasticidad precio-volumen. Se modela la relación no paramétrica mediante el ajuste de curvas de regresión local suavizada (LOESS) y Modelos Aditivos Generalizados (GAM) sobre el espacio logarítmico:

$$\ln(S_{ij}) = f(\ln(V_{ij})) + \mathbb{I}(Channel_{ij}) + \epsilon_{ij}$$

La dispersión de S_{ij} se condiciona de forma cruzada según el canal de ejecución (**Digital** vs. **Manual**) y la tipología de producto (**Spot** vs. **Forward**). Dado el severo alejamiento de la normalidad y la naturaleza acotada inferiormente por cero de los spreads, se implementa la prueba no paramétrica de Mann-Whitney U (Wilcoxon rank-sum) para contrastar la hipótesis nula de homogeneidad distributiva entre canales, evaluando si la digitalización induce una compresión estadísticamente significativa del spread comercial.

Análisis Temporal de Alta Frecuencia

La dinámica temporal de las transacciones se evalúa en tres escalas jerárquicas: intradía, intra-semana e intra-mes. La distribución horaria de las operaciones se modela mediante estimadores no paramétricos de densidad de kernel (KDE) para contrastar empíricamente si la moda de la mesa cambiaria exhibe la concentración teórica bajo la distribución Beta programada.

Para las escalas intra-semana e intra-mes (esta última fraccionada en terciles: *Early*, *Mid*, *Late*), se analiza la concentración del volumen y del spread. Las asimetrías operativas inter-temporales se validan formalmente mediante la prueba no paramétrica de Kruskal-Wallis bajo la hipótesis nula de que las medianas de los subperíodos son idénticas. Ante el rechazo de H_0 , se despliega un análisis *post-hoc* mediante la prueba de comparaciones múltiples de Dunn, aplicando el método de Holm-Bonferroni para el control estricto de la tasa de error por familia (FWER).

Balance del Flujo, Pipeline de Divisas y Direccionalidad

La exposición cambiaria del portafolio se analiza mediante una tabla de contingencia bi-dimensional generalizada que cruza la direccionalidad del flujo neto ($\text{Flow_Direction}_{ij} \in \{\text{Buy USD}, \text{Sell USD}, \text{Non-USD}\}$) con el par de divisas transado ($\text{Currency_Pair}_{ij}$). La hipótesis de simetría y neutralidad del flujo del banco se contrasta mediante una prueba de independencia de χ^2 :

$$\chi^2 = \sum_{r=1}^R \sum_{c=1}^C \frac{(O_{rc} - E_{rc})^2}{E_{rc}}$$

Donde O_{rc} representa las frecuencias observadas y E_{rc} las frecuencias esperadas bajo independencia ósea, simetría perfecta de mercado. Se analiza analíticamente cómo estas frecuencias impactan el diferencial entre la tasa de referencia interbancaria (Market_Rate_{ij}) y la tasa final pactada con el cliente (Deal_Rate_{ij}).

5.2.2. Análisis Portafolio de Clientes

En esta sección, la unidad de observación se traslada de la transacción individual (ij) al espacio indexado a nivel de cliente (i) en la base clientes. Este cambio de granularidad permite el estudio del comportamiento analítico agregado, la concentración de ingresos y las asimetrías en el desempeño de la fuerza de ventas.

Desigualdad, Concentración de Ingresos y Efecto Pareto

Con el fin de cuantificar la concentración y la desigualdad en la distribución del volumen global capturado (*Bank_Volume_i*) y del ingreso total generado (*Total_Revenue_i*), se modela de forma explícita la Curva de Lorenz $L(p)$ (Gastwirth, 1972). El grado de concentración del portafolio se indexa mediante el cálculo numérico del Coeficiente de Gini (G):

$$G = 1 - 2 \int_0^1 L(p) dp = \frac{\sum_{i=1}^n \sum_{j=1}^n |x_i - x_j|}{2n^2 \bar{x}}$$

Un coeficiente $G \rightarrow 1$ proveerá la evidencia empírica formal para validar la existencia del Efecto Pareto en la banca corporativa, caracterizado por la dominancia de un subconjunto denso de clientes institucionales. Complementariamente, la dinámica de actividad se evalúa mediante un análisis bivariado entre las métricas de retención y obsolescencia operacional: Días Activos (*Active_Days_i*) y Recencia (*Recency_Days_i*).

Evaluación de Desempeño y Asignación Comercial (Sales Performance)

Se analiza la estructura de asignación del portafolio analizando la distribución de las tres macro-métricas comerciales: ingresos consolidados, volumen transado y frecuencia de transacciones (TRX) condicionados al identificador de ventas (*Sales_ID_i*). Se contrasta si la regla de negocio estructural de la mesa (concentración masiva de clientes transaccionales pequeños en el ejecutivo *Sales 1* frente a una distribución homogénea y de alto valor corporativo entre los ejecutivos *Sales 2* a *Sales 5*) es estadísticamente verificable. Para ello, se recurre a la prueba de Kruskal-Wallis junto a pruebas de homogeneidad de varianza (prueba de Levene robusta basada en la mediana).

Espacio de Características Conductuales y Diagnóstico Multivariado

Como fase exploratoria y de preparación para los algoritmos de reducción de dimensionalidad y aprendizaje no supervisado (*clustering*), se ejecutó un riguroso proceso de ingeniería y selección de características (*Feature Selection*) sobre el cubo de datos consolidado a nivel de cliente (*Customer 360*). El objetivo de esta fase fue identificar y neutralizar dependencias algebraicas exactas originadas por la lógica contable intrínseca de la mesa de dinero, previo a la proyección geométrica de los datos.

Diagnóstico de Singularidad Computacional y Colinealidad Estructural

Dada la dimensionalidad inicial del portafolio —compuesto por 31 características operativas y financieras—, someter la totalidad de las variables a modelos multivariados sin un filtro previo violaría los supuestos fundamentales del Álgebra Lineal. El diagnóstico inicial sobre la matriz de correlación completa reveló la existencia de colinealidad perfecta estructural y singularidad computacional.

Esta condición no responde a un fenómeno estocástico, sino a la naturaleza del Proceso Generador de Datos (DGP), el cual refleja con exactitud las identidades contables de una tesorería corporativa mediante relaciones algebraicas cerradas. La inclusión simultánea de métricas derivadas (como calcular el ingreso medio a partir del volumen total y la frecuencia) produce correlaciones de Pearson iguales a 1. Matemáticamente, esta condición colapsa el espacio vectorial, manifestándose en un determinante de la matriz de correlación tendente a cero y Factores de Inflación de la Varianza (VIF) asintóticos, lo que impide la inversión de la matriz hessiana.

Protocolo de Selección de Características (*Feature Selection*)

Para garantizar la estabilidad algebraica sin sacrificar la riqueza analítica del comportamiento del cliente, se implementó un protocolo heurístico de exclusión basado en cuatro criterios estrictos:

1. **Exclusión de Metadatos:** Descarte de identificadores únicos y marcas de tiempo absolutas (`Client_ID`, `Ultima_Trx`, `Client_Name`, `Sales_ID`).
2. **Eliminación de Identidades Algebraicas:** Purga de variables “hijas” derivadas aritméticamente de variables “padres” ya presentes en la base. Se excluyeron: `Average_Deal_Size` (cociente entre volumen y transacciones), `Average_Revenue`, `Revenue_Share_Pct`, `Total_Wallet` (circularidad algebraica), `sow_score` (variable latente auxiliar), y `Total_Revenue` (ya capturada en `CLV_Proxy` mediante un componente de valor futuro).
3. **Eliminación por Colinealidad Empírica Extrema:** Exclusión de variables cuya correlación empírica superó el umbral crítico de $r = 0.90$. Se omitió `Active_Days` ($r = 0.981$ con `Count_of_Deals`), sustituyéndose conceptualmente por `HHI_Temporal`, métrica que captura la distribución de la actividad de forma no lineal. Asimismo, `Revenue_per_Day` fue conservada únicamente como variable descriptiva para el perfilamiento posterior de *clusters*, pero excluida del espacio de características base.
4. **Mitigación de Redundancias Derivadas:** Exclusión de `Pct_Buy_USD` y `Pct_Sell_USD`, cuya información queda íntegramente contenida en el índice `USD_Flow_Direction` (log-ratio de volúmenes comprados y vendidos), el cual captura la direccionalidad neta del flujo cambiario sin saturar el modelo.

Consolidación del Espacio Vectorial Depurado

La aplicación de este protocolo convergió en un vector conductual definitivo compuesto por catorce (14) dimensiones genuinamente independientes, abarcando espectros de escala, rentabilidad relativa, riesgo cambiario, adopción tecnológica, consistencia operativa y valor de ciclo de vida:

- | | |
|-----------------------------------|--------------------------------|
| ■ <i>Bank_Volume</i> | ■ <i>USD_Flow_Direction</i> |
| ■ <i>Count_of_Deals</i> | ■ <i>Diversification_Score</i> |
| ■ <i>Average_Spread_BPS</i> | ■ <i>CV_Volume</i> |
| ■ <i>Spread_vs_Benchmark</i> | ■ <i>HHI_Temporal</i> |
| ■ <i>Spread_Price_Sensitivity</i> | ■ <i>Recency_Days</i> |
| ■ <i>Porcentaje_Spot</i> | ■ <i>CLV_Proxy</i> |
| ■ <i>Porcentaje_Digital</i> | ■ <i>Share_of_Wallet</i> |

Diagnóstico de Adecuación Muestral

La pertinencia estadística de someter el espacio de características resultante a un Análisis de Componentes Principales se evaluó mediante dos pruebas complementarias y de uso estándar en la literatura de análisis multivariado. La prueba de esfericidad de **Bartlett** contrasta la hipótesis nula de que la matriz de correlación observada es estadísticamente equivalente a una matriz identidad, condición bajo la cual ningún método de reducción dimensional basado en correlaciones compartidas resultaría informativo. El índice de adecuación muestral de **Kaiser-Meyer-Olkin** (KMO) cuantifica, para el conjunto de variables y para cada variable individualmente (estadístico MSA_i), la proporción de varianza que puede atribuirse a factores comunes subyacentes frente a varianza idiosincrática, siguiendo la escala de interpretación propuesta por Kaiser (1974): valores inferiores a 0.50 se consideran inaceptables, el intervalo 0.50-0.59 mediocre, 0.60-0.69 aceptable, 0.70-0.79 bueno, 0.80-0.89 notable y valores iguales o superiores a 0.90 excelentes. Adicionalmente, se calculó el determinante de la matriz de correlación y el Factor de Inflación de la Varianza (VIF) de cada variable –obtenido como la diagonal principal de la inversa de la matriz de correlación– para verificar la ausencia de multicolinealidad severa, empleando el umbral crítico convencional de $VIF > 10$ Kennedy (2008).

5.3. Reducción Dimensional y Determinación del Agrupamiento

The more data you get, the less you know what's going on, and the more iatrogenics you will cause. People are still under the illusion that science means more data.

Nassim Nicholas Taleb.

Análisis de Componentes Principales

Confirmada la adecuación muestral, se aplicó el Análisis de Componentes Principales (PCA) sobre la matriz de características estandarizada (transformación Z-score, $\mu = 0$, $\sigma = 1$), con el objetivo de proyectar las observaciones en un sistema de coordenadas ortogonales que concentre la mayor proporción de varianza compartida en el menor número de dimensiones. La determinación del número de componentes a retener se abordó mediante la aplicación conjunta de múltiples criterios no necesariamente convergentes, práctica recomendada en la literatura especializada Johnson y Wichern (2007) y Jolliffe (2002) frente a la adopción acrítica de un único criterio: el criterio de Kaiser, que retiene componentes con eigenvalue superior a la unidad Kaiser (1960); el examen visual del gráfico de sedimentación o *scree plot*, buscando el punto de inflexión en la pendiente de los eigenvalues Cattell (1966); y la regla de varianza acumulada, con umbrales de referencia de 70-80 % para aplicaciones en ciencias sociales y de negocios Hair et al. (2019).

Dado que el propósito del PCA en la presente investigación es servir como insumo geométrico para un algoritmo de agrupamiento no supervisado subsiguiente, y no la interpretación factorial autónoma propia del análisis factorial exploratorio, se consideró adicionalmente la literatura especializada en la intersección metodológica entre reducción dimensional y *clustering* Ding y He (2004) y Yeung y Ruzzo (2001), la cual advierte que un truncamiento guiado exclusivamente por el criterio del codo puede eliminar dimensiones de varianza moderada que, pese a no ser dominantes, resultan determinantes para la separación geométrica de subgrupos genuinos. En consecuencia, ante la posible divergencia entre los criterios clásicos de retención, se optó por evaluar empíricamente el desempeño de distintas especificaciones del número de componentes en la etapa de agrupamiento, en lugar de fijar a priori una única solución basada exclusivamente en criterios de varianza explicada.

Comparación de Rutas hacia el Espacio de Agrupamiento

Con el fin de determinar de manera empírica si el agrupamiento no supervisado debía ejecutarse sobre los *scores* del PCA o directamente sobre las variables originales estandarizadas, se diseñó un esquema comparativo de rutas alternativas. Esta decisión no se asumió a priori: la literatura reconoce ventajas teóricas en ambas aproximaciones –la proyección en componentes ortogonales mitiga la distorsión de las distancias euclidianas inducida por variables correlacionadas y atenúa los efectos adversos de la alta dimensionalidad Ding y He (2004), mientras que el agrupamiento directo sobre las variables originales preserva la interpretabilidad sustantiva de los centroides resultantes en unidades de negocio Milligan y Cooper (1985)–, por lo que la selección final se fundamentó en evidencia empírica de calidad de agrupamiento más que en preferencia teórica.

Se definieron cuatro rutas alternativas: tres basadas en distintos números de componentes principales, correspondientes a los criterios de retención discutidos previamente, y una basada en el conjunto completo de variables originales estandarizadas. Para cada ruta, se ejecutó el algoritmo K-Means con un rango de número de clústeres ($k = 2$ a 8), utilizando múltiples reinicios aleatorios (*nstart*) para mitigar la sensibilidad del algoritmo a la inicialización de centroides. La calidad de cada combinación (ruta, k) se evaluó mediante tres índices de validación interna de naturaleza matemática complementaria: el **coeficiente de silueta** promedio, que cuantifica la cohesión intra-cluster relativa a la separación inter-cluster a nivel de observación individual Rousseeuw (1987); el índice de **Calinski-Harabasz**, definido como la razón entre la dispersión inter-cluster y la dispersión intra-cluster, ponderada por los grados de libertad correspondientes Calinski y Harabasz (1974); y el índice de **Davies-Bouldin**, que mide la similitud promedio entre cada cluster y su vecino más cercano, donde valores menores indican una mejor separación Davies y Bouldin (1979).

Validación Complementaria del Número de Clústeres

Como verificación adicional e independiente de la determinación del número óptimo de agrupaciones, se aplicó el procedimiento de votación implementado en el paquete **NbClust** Charrad et al. (2014), el cual calcula simultáneamente un conjunto extenso de índices de validación de *clustering* (aproximadamente veintiséis, incluyendo los estadísticos de Hubert, Dindex, Duda, KL, entre otros) y determina el número de clústeres mediante una regla de mayoría entre dichos índices. Este procedimiento se ejecutó de manera independiente para cada una de las cuatro rutas evaluadas, permitiendo contrastar si la solución óptima en términos de número de clústeres resultaba sensible a la representación geométrica del espacio de características (componentes principales frente a variables originales) o si, por el contrario, constituía una propiedad estructural robusta de los datos subyacentes.

La combinación final de ruta de reducción dimensional y número de clústeres se determinó mediante la convergencia de evidencia entre los tres índices de validación interna y el

procedimiento de votación de **NbClust**, privilegiando la triangulación de múltiples criterios estadísticos independientes por sobre la adopción de un único indicador, en línea con las buenas prácticas metodológicas documentadas en la literatura de análisis de conglomerados Johnson y Wichern (2007) y Milligan y Cooper (1985).

Comparación de Algoritmos de Partición

Determinada provisionalmente la especificación de ruta y número de clústeres, se evaluó la sensibilidad de dicha solución frente a la elección del algoritmo de agrupamiento mediante la comparación de cuatro métodos con fundamentos matemáticos distintos: K-Means Lloyd (1982) y MacQueen (1967), clustering jerárquico aglomerativo bajo el criterio de Ward Murtagh y Legendre (2014) y Ward (1963), un esquema híbrido en el que los centroides obtenidos del corte del dendrograma de Ward se emplearon como inicialización determinística de K-Means Milligan (1980) y Punj y Stewart (1983), y *Partitioning Around Medoids* (PAM), variante robusta de la partición por centros que sustituye centroides por medoides –observaciones reales– y minimiza distancias absolutas en lugar de distancias al cuadrado Kaufman y Rousseeuw (1990). Esta última propiedad confiere a PAM una resistencia sustancialmente mayor a la influencia de valores atípicos en comparación con K-Means y Ward, ambos basados en la minimización de sumas de cuadrados.

Para cada algoritmo se examinó tanto el desempeño en el índice de silueta promedio bajo la especificación de k previamente determinada, como –en el caso particular del método jerárquico– la estructura completa de fusión representada en el dendrograma, cuyo examen permite identificar el número de clústeres asociado al mayor salto de altura entre fusiones consecutivas de forma enteramente independiente a cualquier valor de k fijado a priori.

Diagnóstico de Sensibilidad a Valores Atípicos

La literatura de análisis de conglomerados documenta de manera extensa que los algoritmos fundamentados en la minimización de sumas de cuadrados son particularmente susceptibles a la influencia desproporcionada de un reducido número de observaciones extremas, las cuales pueden inducir la formación de agrupaciones espurias que no reflejan estructura genuina en los datos sino la respuesta mecánica del algoritmo ante dichas observaciones Kaufman y Rousseeuw (1990) y Milligan (1980). En consecuencia, ante la eventual discrepancia en el número de clústeres sugerido por algoritmos de sensibilidad conocida a valores atípicos (K-Means, Ward, Híbrido) frente a un algoritmo diseñado específicamente para mitigar dicha sensibilidad (PAM), se estableció un protocolo de diagnóstico en tres etapas.

En primer lugar, se examinó si las observaciones asociadas a la agrupación discrepante presentaban características de baja frecuencia transaccional susceptibles de generar inestabilidad en la estimación de variables conductuales derivadas de estadísticos intra-cliente (por

ejemplo, coeficientes de correlación o de variación calculados sobre un número reducido de transacciones). En segundo lugar, se aplicó el algoritmo de agrupamiento basado en densidad *DBSCAN* Ester et al. (1996) sobre el mismo espacio de características, con el propósito de verificar formalmente si dichas observaciones constituían puntos de baja densidad (clasificados por el algoritmo como ruido, en lugar de pertenecientes a una región densa propia) o si, por el contrario, conformaban un agrupamiento denso y genuino. El parámetro de radio de vecindad (ε) se determinó mediante el examen del gráfico de distancia al k -ésimo vecino más cercano Ester et al. (1996), fijando el número mínimo de puntos por vecindario (*minPts*) en un valor equivalente a la dimensionalidad del espacio de características más uno, conforme a la heurística convencional para esta técnica.

En tercer lugar, condicional a la confirmación de que las observaciones discrepantes constituían valores atípicos de densidad genuinos, se procedió a su exclusión del conjunto de datos y a la re-ejecución íntegra del protocolo de determinación del número de clústeres –índices de silueta, Calinski-Harabasz y Davies-Bouldin para K-Means; examen de saltos de altura para Ward; silueta para PAM; y votación de *NbClust*– sobre el espacio de características depurado, manteniendo invariante la proyección de componentes principales previamente estimada, con el fin de aislar el efecto de la exclusión de valores atípicos del efecto de una eventual re-estimación de la reducción dimensional.

Se emplea una visualización no-lineal de la estructura de clustering mediante t-SNE (van der Maaten & Hinton, 2008). Si bien el PCA fue el método correcto para la reducción dimensional empleada como insumo del clustering (por su interpretabilidad algebraica y su propiedad de maximizar la varianza explicada en dimensiones sucesivas ortogonales), t-SNE aporta valor como herramienta complementaria de visualización para confirmar visualmente la separación geométrica de los segmentos en un espacio bidimensional no-lineal y para comunicar los resultados a audiencias no técnicas.

Validación de la Estructura mediante Conocimiento del Proceso Generador de Datos

Dado que la base de clientes analizada se deriva de un proceso generador de datos sintético con una estructura poblacional conocida a priori –dos arquetipos de clientes corporativos con parámetros de actividad transaccional y volumen sistemáticamente diferenciados–, se incorporó una validación adicional no disponible en el análisis de datos observacionales convencional: el contraste directo entre la partición obtenida por los algoritmos de agrupamiento y la pertenencia real de cada cliente al arquetipo subyacente. Dicho contraste se cuantificó mediante el Índice de Rand Ajustado Hubert y Arabie (1985) entre la partición algorítmica y la etiqueta de arquetipo verdadera, lo cual permite determinar en qué medida la estructura de agrupamiento recuperada de manera no supervisada corresponde a un mecanismo generador conocido, constituyendo una forma de validación externa de la solución de *clustering* –en el sentido de Johnson y Wichern (2007)–, complementaria a los índices de validación interna empleados en las etapas anteriores.

Caracterización Descriptiva de los Segmentos

La caracterización de los segmentos resultantes de la partición final se realizó sobre un conjunto ampliado de variables que comprendió, además de las catorce dimensiones del espacio de características depurado empleado en el análisis de agrupamiento, cinco variables descriptivas que habían sido excluidas de dicho espacio por dependencia algebraica o colinealidad empírica pero que conservan pleno valor interpretativo para el perfilamiento de negocio: `Total_Revenue`, `Average_Deal_Size`, `Average_Revenue`, `Active_Days` y `Revenue_per_Day`. La inclusión de estas variables en la etapa de caracterización –pero no en la de agrupamiento– es coherente con la distinción metodológica entre variables de partición, que deben ser estadísticamente independientes para no distorsionar la geometría del clustering, y variables de descripción, cuya utilidad reside precisamente en facilitar la interpretación sustantiva de los segmentos obtenidos en el lenguaje operativo del negocio cambiario (Hair et al., 2019).

Para cada variable se calcularon la media, la mediana, la desviación estándar y el rango intercuartílico por segmento. Las diferencias entre segmentos se evaluaron mediante la prueba no paramétrica de Mann-Whitney U (Wilcoxon, 1945), preferida sobre pruebas paramétricas dado el patrón de asimetría pronunciada y colas pesadas documentado en la fase exploratoria para las principales variables de volumen e ingreso. Para controlar la tasa de error de tipo I derivada de la realización de comparaciones múltiples en paralelo, se aplicó la corrección de Bonferroni sobre los p -valores obtenidos (Bonferroni, 1936), adoptando un umbral de significancia corregido de α/m , donde m es el número total de pruebas simultáneas. La magnitud de la diferencia entre grupos se cuantificó adicionalmente mediante el coeficiente de efecto $r = |W|/\sqrt{n_1 \cdot n_2}$, derivado del estadístico de Wilcoxon, siguiendo la recomendación de Rosenthal (1994) para la interpretación de efectos en pruebas no paramétricas: valores de $r < 0.10$ indican efecto nulo, 0.10–0.29 pequeño, 0.30–0.49 mediano, y $r \geq 0.50$ grande.

Diagnóstico de Heterogeneidad Interna

El análisis de agrupamiento identificó dos segmentos de clientes cuya separación inter-grupal es estadísticamente robusta; no obstante, la presencia de sub-estructura latente dentro de cada segmento constituye una pregunta analítica independiente con implicaciones directas para el diseño de estrategias de relacionamiento diferenciado. Para abordarla formalmente, se implementó un protocolo de diagnóstico de heterogeneidad interna en tres componentes, manteniendo el enfoque en el Nivel 2 definido previamente –diagnóstico sin sub-segmentación formal–, cuya ejecución se reserva para una instancia de investigación futura.

Silueta intra-segmento. Se calculó el coeficiente de silueta para particiones de $k = 2$ a $k = 5$ sub-grupos aplicadas exclusivamente sobre las observaciones de cada segmento por separado, operando en el mismo espacio de cuatro componentes principales. Esta métrica

permite evaluar si las observaciones dentro de un segmento exhiben tendencia a formar sub-agrupaciones cohesivas, independientemente de si dichos sub-grupos serían suficientemente distintos del resto del conjunto completo para emerger en un análisis global.

Varianza intra-segmento por componente principal. Se calculó la proporción de la varianza total de cada componente principal que se encuentra concentrada dentro de cada segmento. Para cada componente j y segmento s , la proporción $\text{Var}(PC_j \mid s)/\text{Var}(PC_j)$ cuantifica qué fracción de la heterogeneidad capturada por esa dimensión latente existe al interior del segmento. Valores superiores al 50 % indican que dicha dimensión de comportamiento opera principalmente como fuente de diferenciación dentro del segmento, más que como separador entre segmentos, constituyendo evidencia de sub-estructura latente en esa dirección específica.

Estadístico de Hopkins. Se aplicó el estadístico de tendencia al agrupamiento de Hopkins (Lawson & Jurs, 1990) sobre las observaciones de cada segmento de manera independiente. Dicho estadístico compara la distribución de distancias entre puntos reales y puntos generados bajo uniformidad aleatoria, produciendo un valor en el intervalo $(0, 1)$: valores cercanos a 0.50 indican ausencia de estructura (distribución uniforme), mientras que valores superiores a 0.65 indican tendencia al agrupamiento, señalando la presencia de sub-estructura latente que una futura sub-segmentación anidada podría recuperar formalmente (Kaufman & Rousseeuw, 1990; Lawson & Jurs, 1990).

6. Resultados

6.1. Análisis de Microestructura y Dinámica Transaccional

6.1.1. Caracterización Univariada, Colas Pesadas e Inflación de Ceros

Los resultados del análisis univariado revelan una estructura clásica de colas pesadas en los volúmenes transados, con una asimetría de 8.22 y una curtosis de exceso de 121 (6.2). El percentil máximo registrado se ubica en USD 93.1 millones. Si bien en la práctica, en el mercado cambiario colombiano, existen operaciones episódicas de mayor envergadura (tales como fusiones, adquisiciones o estructuración de deuda intercompany que superan la barrera de los USD 100 millones), el límite capturado por el DGP modela con alta fidelidad el flujo operativo y recurrente del día a día de la mesa de dinero corporativa, aislando los choques exógenos de volatilidad extrema.

<i>Variable</i>	Media	Mediana	Min	Q1	Q3	CV (%)
<i>USD_Volume</i>	1,201,043	243,991	1,001	55,980	1,133,434	245.28
<i>USD_Revenue</i>	2,184.80	1,157.50	0.00	397.60	3,144.70	120.59
<i>Spread_BPS</i>	105.94	85.37	0.00	47.24	146.56	86.35

Cuadro 6.1: Medidas de tendencia central y dispersión para las principales variables cuantitativas.

De manera similar, los ingresos comparten un comportamiento de colas pesadas, concentración y, de manera adicional, un fenómeno de inflación en ceros del 15 % producto de las operaciones en las que no se carga nada de spread al cliente.

Sí bien, al contrastar la media vs la mediana tanto de los ingresos como de los volúmenes, se

<i>Variable</i>	P95	P99	Máx	% Ceros	Asimetría	Curtosis
<i>USD_Volume</i>	5,230,056	12,976,650	93,099,363	0.00	8.22	121.00
<i>USD_Revenue</i>	7,579.85	11,743.33	30,361.80	15.00	2.06	5.76
<i>Spread_BPS</i>	279.80	413.96	1,180.49	15.00	1.70	5.56

Cuadro 6.2: Medidas de forma distribucional y comportamiento extremo de las principales variables cuantitativas.

ve claramente que aquellos valores de los deciles superiores, mueven el promedio hacia estas colas pesadas de transacciones grandes o de oportunidades en las cuales se logra cobrar un spread alto.




Figura 6.1: Transformación Logarítmica con desplazamiento de las ganancias en dólares

Al evaluar la hipótesis de lognormalidad para el ingreso comercial mediante las pruebas de Lilliefors ($D = 0.043$, $p < 0.001$) y Anderson-Darling ($A^2 = 95.23$, $p < 0.001$), se observa un rechazo formal de la hipótesis nula. Este fenómeno constituye, en primera instancia, un resultado asintótico estándar ante muestras de gran escala ($N \approx 35,000$), donde la potencia de los contrastes paramétricos penaliza desviaciones infinitesimales. No obstante, el bajo valor del estadístico de Kolmogorov-Smirnov ($D = 4.3\%$) denota una estrecha proximidad geométrica con la distribución teórica. Más allá del efecto muestral, el rechazo encuentra su justificación estructural en la naturaleza bimodal que exhibe el histograma empírico del revenue. Dado que la densidad Lognormal es estrictamente unimodal, la presencia de múltiples modas —acentuada por la estructura de tipo *Hurdle* donde el 15.00 % de las observaciones acumulan masa de probabilidad exactamente en el origen ($R_{ij} = 0$)— evidencia que los da-

tos provienen de una mezcla de distribuciones (*mixture distributions*). Este comportamiento valida empíricamente la coexistencia de flujos operativos altamente competitivos indexados a cero margen junto a transacciones corporativas tradicionales de rendimiento positivo.




Figura 6.2: Transformación logarítmica del volumen en dolares

De manera análoga, el contraste de lognormalidad sobre la distribución de los volúmenes transados mediante las pruebas de Lilliefors ($D = 0.039$, $p < 0.001$) y Anderson-Darling ($A^2 = 123.27$, $p < 0.001$) ratifica el rechazo estadístico de la hipótesis nula. A pesar de que la distancia vertical máxima entre la función de distribución acumulada empírica y la teórica es de apenas el 3.9%, la morfología bimodal del volumen impide el ajuste óptimo de una población homogénea y unimodal. Este patrón morfológico actúa como la firma empírica del Proceso Generador de Datos (DGP), reflejando con alta fidelidad la segmentación intrínseca de la microestructura cambiaria institucional: por un lado, un nicho transaccional de alta frecuencia y bajo valor nominal ejecutado por firmas medianas (primera moda); y por el otro, un segmento de tesorerías corporativas a gran escala que transan bloques de alta denominación (segunda moda). Este hallazgo no solo describe el ecosistema transaccional, sino que provee el sustento metodológico definitivo para justificar el análisis analítico de particionamiento y segmentación de clientes en las secciones ulteriores de esta investigación.

6.1.2. Microeconomía del Spread: Economías de Escala, Efecto Canal/Producto

El 95 % de las transacciones son compra corriente de contado (Spot), el restante 5 % son derivados a plazos (Forwards). Si se analiza las transacciones por canal de ejecución de las instrucciones, se da de cuenta que el 80 % se cierran a través de plataformas digitales propias del banco o integradas como APIs o Bloomberg y el 20 % por medio de canales manuales como por ejemplo vía telefónica. Las pares de monedas representados en la base de datos se distribuyen de la siguiente manera:

- | | |
|------------------|-------------------|
| ■ EUR/GBP: 3.4 % | ■ GBP/JPY: 3.2 % |
| ■ EUR/JPY: 3.3 % | ■ GBP/USD: 2.2 % |
| ■ EUR/USD: 2.2 % | ■ USD/COP: 85.6 % |

Tras evaluar la dependencia de la variable categórica Producto respecto a los spreads comerciales se obtuvo que la probabilidad de que una operación se cierre sin margen para el banco no está ligada a la complejidad del instrumento (si es una compra corriente de contado o un derivado a plazo), sino que responde a otros factores transversales, como el tamaño del cliente, acuerdos pactados, el canal técnico de ejecución o los montos tranzados.

La relación empírica entre el margen cobrado y el tamaño de la transacción se evaluó formalmente en el espacio logarítmico mediante el ajuste de una regresión local suavizada (LOESS) (Figura 6.3). La trayectoria estimada exhibe un comportamiento estrictamente decreciente a lo largo de todo el dominio del volumen transado. Desde la perspectiva de la teoría microeconómica de la firma, este patrón constituye la validación empírica fundamental de las economías de escala en la fijación de precios de la mesa de dinero. Al encontrarse las variables en escala logarítmica ($\ln(S_{ij})$ frente a $\ln(V_{ij})$), la pendiente de la curva actúa como un estimador directo de la elasticidad-precio del volumen; la persistencia de esta trayectoria descendente demuestra que el poder de negociación del cliente o la política de descuento institucional del banco indexa una compresión marginal del spread por cada dólar incremental transado, favoreciendo sistemáticamente a las operaciones de mayor envergadura nominal.

Para evaluar si esta estructura de incentivos se encuentra condicionada por la microestructura tecnológica, se contrastó la hipótesis nula de homogeneidad posicional en los spreads mediante la prueba no paramétrica de Mann-Whitney U (Wilcoxon rank-sum). El resultado arroja un rechazo absoluto de la neutralidad del canal ($W = 85,701,065$, $p < 2.2e^{-16}$), demostrando que las distribuciones de **Digital** y **Manual** no son equivalentes. Contrario a la intuición comercial ordinaria de cobrar una prima por conveniencia tecnológica, el canal electrónico desplaza la nube de puntos hacia niveles de spreads sistemáticamente más bajos. Este comportamiento responde a tres factores estructurales: i) la transparencia competitiva derivada de la comparación de precios de los clientes en plataformas electrónicas, ii) las eficiencias de una ejecución automatizada con menor costo marginal, y iii) una estrategia

orientada a la captura masiva de participación de mercado (*market share*). De este modo, la digitalización interactúa con las economías de escala preexistentes, aplicando reglas algorítmicas de precios más agresivas que aceleran la compresión del spread en los flujos corporativos de alta denominación.

Esto se complementa con la estimación de un Modelo Lineal Ordinario de referencia, donde:

$$\begin{aligned}\ln(\widehat{\text{Revenue}}_{ij}) = & -0.4673 + 0.6506 \cdot \ln(\text{Volume}_{ij}) + 0.1993 \cdot \text{Manual}_{ij} \\ & + 0.00002 \cdot [\ln(\text{Volume}_{ij}) \times \text{Manual}_{ij}]\end{aligned}$$

Al ser un modelo log-log, el coeficiente $\beta_1 = 0.6506$ es una elasticidad directa. Significa que, manteniendo el canal constante (en el canal de referencia, que es Digital), un incremento del 1 % en el volumen de la transacción se traduce en un aumento del 0.65 % en el ingreso comercial. Al ser menor que 1, reconfirma de manera predictiva las economías de escala: el ingreso crece a un ritmo decreciente porque el spread se va comprimiendo a mayor volumen. Con un coeficiente $\beta_2 = 0.1993$, para transacciones del mismo tamaño, el canal Manual genera sistemáticamente mayores ingresos (un $\approx 19.9\%$ más) que el canal Digital, lo cual valida el test de Mann-Whitney U anterior.

Al evaluar el supuesto de homocedasticidad para este modelo con gran poder predictivo ($R^2 = 92.23\%$), se obtiene la siguiente gráfica 6.4, en la cual se observa como la línea LOESS (en naranja) se mantiene superpuesta sobre el cero ($y = 0$), adicional a que la nube se distribuye de manera homogénea tanto arriba como abajo de la línea cero, concentrando la gran mayoría de los residuos entre -0.5 y 0.5. Sin embargo, este modelo presenta un sesgo de truncamiento ya que no considera el 15 % transacciones en las cuales el revenue es igual a cero. Este sesgo de selección obliga la implementación posterior de modelos con inflación de ceros, Modelo de Selección de Heckman o Modelo de Dos Partes (*Hurdle Model*).

La estimación de la primera fase del modelo de dos partes (*Hurdle Model*), orientada a modelar la probabilidad de generación de ingresos positivos frente a márgenes nulos, evidenció la presencia del fenómeno econométrico de separación perfecta. El algoritmo de optimización de máxima verosimilitud numérica no logró convergencia debido a que la combinación lineal del volumen transado y el canal predice de forma infalible la variable dependiente binaria, colapsando la devianza residual a un valor asintótico cercano a cero (3.017).

Lejos de constituir una falla metodológica, este comportamiento revela que el Proceso Generador de Datos institucional opera bajo una regla de decisión estrictamente determinística y no estocástica para la exención de spreads comerciales (e.g., políticas corporativas rígidas de cero-margen indexadas al tamaño nominal de la transacción). Por consiguiente, ante la ausencia de una naturaleza probabilística en la barrera del cero, la estructura del *Hurdle Model* se simplifica de forma analítica: la primera etapa se define mediante una función indicadora determinística $I(\cdot)$ que segmenta el umbral de exención, mientras que la intensidad




Figura 6.3: LOESS sobre el espacio logarítmico del margen de ganancias en puntos básicos y el volumen en dólares.

y magnitud del ingreso condicional positivo queda perfectamente parametrizada por la especificación log-lineal (OLS) expuesta en la sección previa, garantizando una modelación integral e insesgada de la operación cambiaria.

6.1.3. Análisis Temporal de Alta Frecuencia

La dimensión temporal de alta frecuencia a nivel intradía se evaluó mediante la estimación de densidad de kernel (KDE) sobre las marcas horarias de ejecución (Figura 6.5). La morfología de la densidad estimada modela con alta fidelidad la microestructura del mercado cambiario institucional colombiano. Se observa un comportamiento asimétrico que inicia con operaciones marginales de apertura entre las 07:00 y las 07:59 horas, correspondientes a las órdenes corporativas preliminares de la mañana. La actividad comercial se concentra masivamente en la franja de alta liquidez (entre las 08:30 y las 12:59 horas), período en el cual operan los sistemas oficiales de negociación interbancaria (*Spot*) como SET-FX. Posterior a las 13:00 horas, coincidiendo con el cierre de la compensación local, la densidad registra un descenso pronunciado pero continuo; este comportamiento describe adecuadamente la dinámica de una mesa de dinero real, donde el flujo residual de la tarde se mantiene activo para canalizar operaciones de derivados (*Forwards*) o estructuraciones indexadas a mercados internacionales.




Figura 6.4: Gráfico de dispersión de los residuos del modelo OLS baseline

Para identificar asimetrías operativas, se aplicó la prueba no paramétrica de Kruskal-Wallis evaluando el comportamiento del volumen frente a los días de la semana y los terciles mensuales (*Early*, *Mid*, *Late*). El contraste intra-semana arroja que las fluctuaciones del volumen entre jornadas laborales no son estadísticamente significativas ($\chi^2 = 1.564$, $p = 0.815$), pese a que la proporción de los días de la semana muestra a los lunes con un 15 %, martes con un 25 %, miércoles con 23 %, jueves con 20 % y viernes 18 %. De manera homóloga, la hipótesis de un incremento sistemático en la liquidez transada durante el cierre de mes queda desvirtuada por el contraste intra-mes ($\chi^2 = 1.510$, $p = 0.470$), lo que impidió la ejecución de pruebas *post-hoc* de comparaciones múltiples ante la ausencia de desplazamientos estocásticos (Proporciones: *Early*: 25 %, *Mid*: 34 %, *Late*: 41 %). Esto evidencia que el portafolio de clientes corporativos de la entidad se encuentra altamente diversificado en sus necesidades de flujo cambiario, y que el uso de coberturas estructurales programadas diluye los choques de liquidez del calendario civil, consolidando un flujo transaccional estable y agnóstico a la estacionalidad temporal.

6.1.4. Balance de Flujo, Pipeline de Divisas y Direccionalidad

La evaluación empírica de la exposición cambiaria mediante el contraste bidimensional generalizado confirma un rechazo categórico de la hipótesis de simetría y neutralidad perfecta del flujo ($\chi^2 = 69,872$, $df = 14$, $p < 0.001$). La divergencia estructural entre las frecuencias observadas (O_{rc}) y las esperadas (E_{rc}) bajo el supuesto estocástico de independencia revela un




Figura 6.5: Distribución del tiempo intra-día en que se ejecutan las operaciones en la mesa de dinero

mercado corporativo altamente polarizado y dominado por las puntas locales frente al dólar americano: las transacciones se concentran masivamente en flujos de compra a través del par USD/COP (13,326 operaciones) y de venta en COP/USD (16,510 operaciones), relegando los cruces de monedas terceras (*Non-USD*) a un rol marginal y balanceado de portafolio.

Este marcado desbalance de inventario ejerce una fuerza de transmisión directa sobre la fijación de precios de la mesa de dinero, manifestándose de forma explícita en las asimetrías de los diferenciales de tasa ($|Deal_Rate - Market_Rate|$). Los datos demuestran que las operaciones que involucran la conversión física de la moneda local (COP) registran distorsiones nominales promedio elevadas y opuestas en signo (-43.05 para compras y $+42.71$ para ventas) como mecanismo de compensación por el costo microeconómico de manejo de inventario, mientras que los diferenciales de los pares internacionales puros (e.g., EUR/USD, GBP/USD, EUR/GBP) convergen de forma asintótica hacia márgenes infinitesimales cercanos a cero debido a la profundidad y alta liquidez de las pantallas interbancarias globales.

6.2. Análisis Portafolio de Clientes

Desigualdad, Concentración de Ingresos y Efecto Pareto

La cuantificación de la desigualdad en el portafolio mediante el coeficiente de Gini revela una estructura dual de concentración. El volumen transado exhibe un Gini de 0.81, reflejando una dependencia estructural extrema de un subconjunto marginal de clientes institucionales. No obstante, la curva de Lorenz para los ingresos generados (Figura 6.6), con un Gini de 0.64, evidencia una distribución notablemente menos concentrada.




Figura 6.6: Curva Lorenz para los ingresos generados

La disparidad morfológica entre ambas curvas valida una segmentación económica subyacente. Mientras la curva de volumen (Figura 6.7) presenta una convexidad extrema —caracterizada por una trayectoria prácticamente horizontal hasta el octavo decil ($p = 0.8, L(p) \approx 0$) y un ascenso abrupto final—, la curva de ingreso manifiesta un perfil significativamente más elástico. Este fenómeno confirma la existencia de un mecanismo de pricing discriminatorio: el segmento del 80 % de clientes con menor actividad transaccional aporta cerca del 25 % del ingreso total ($L(0.8) \approx 0.25$), frente a una contribución marginal en volumen.

En consecuencia, el *Efecto Pareto* se manifiesta con mayor nitidez en la captura de liquidez que en la captura de rentabilidad. La mesa de dinero extrae rentabilidad mediante un markup más elevado en el segmento de baja intensidad operativa, mientras que el segmento masivo —aquel que genera la inflexión abrupta en la curva de volumen— es gestionado bajo un esquema de economías de escala, donde el margen unitario se sacrifica en favor de la profundidad transaccional y la captura de cuota de mercado. Esta divergencia sugiere que la diversificación del Total Revenue es, paradójicamente, más robusta que la diversificación de las operaciones físicas de divisas, otorgando al banco una estabilidad financiera que la simple métrica de volumen ocultaría.




Figura 6.7: Curva Lorenz para los volúmenes generados

Evaluación de Desempeño y Asignación Comercial

Los resultados del contraste empírico ratifican la existencia de una segmentación operativa binaria en la mesa de dinero. La prueba de Kruskal-Wallis ($\chi^2 = 1650.1, p < 0.001$) rechaza contundentemente la hipótesis de homogeneidad en la generación de ingresos por transacción entre ejecutivos (*Salespersons*). Esta divergencia se explicita en el perfil del ejecutivo *Sales 1*, quien concentra el 45 % del volumen total de transacciones ($N = 15,689$) con un ingreso promedio unitario de \$1,162, operando como un nodo de alta eficiencia para flujos transaccionales de bajo margen.

En contraste, el grupo *Sales 2-5* exhibe un modelo de *Relationship Banking* fundamentado en la captura de valor: con un ingreso medio por operación próximo a los \$3,000 y un volumen medio de \$2.1 millones, este equipo gestiona la complejidad institucional de alto impacto. La significancia estadística obtenida en la prueba de Levene para la homogeneidad de varianza ($F = 2307.6, p < 0.001$) subraya que no solo la rentabilidad media difiere, sino que la volatilidad y el perfil de riesgo inherente a las operaciones de cada ejecutivo son estructuralmente distintos. Estos resultados consolidan la evidencia de una especialización funcional orientada a la segmentación del mercado entre el segmento masivo (*Sales 1*) y el segmento de asesoría financiera corporativa (*Sales 2-5*), optimizando así la capacidad instalada frente a las diversas exigencias de liquidez y márgenes de los clientes.




Figura 6.8: Diagramas de Cajas y Bigotes para la distribución de los ingresos por Ejecutivo

6.3. Reducción de Dimensionalidad

6.3.1. Protocolo de Selección de Características y Prevención de Singularidad

Tras consolidar el espacio de características conductuales de 14 dimensiones. Este subespacio retiene de manera ortogonal toda la información primitiva de rentabilidad, riesgo y comportamiento transaccional del cliente, permitiendo que el Análisis de Componentes Principales (PCA) modele eficientemente la varianza latente sin el sesgo derivado de redundancias matemáticas.

Al evaluar la matriz de correlación del espacio de características depurado ($\mathbf{X}_{clean}$), el determinante arrojó un valor estrictamente positivo de 0.000136, confirmando matemáticamente la resolución de la singularidad computacional 6.9. El diagnóstico de multicolinealidad residual mediante el Factor de Inflación de la Varianza ubicó el valor máximo en **Bank_Volume** ($VIF = 13.24$), seguido de **Count_of_Deals** ($VIF = 9.10$) y **Average_Spread_BPS** ($VIF = 8.54$); el resto de las variables registró VIFs inferiores a 6, sin que ninguna otra superara el umbral crítico de 10. El valor de **Bank_Volume** refleja su covarianza natural con la frecuencia operativa del cliente (**Count_of_Deals**, $r = 0.894$); una correlación intrínseca a la microestructura del mercado institucional, donde el volumen transado y la actividad operativa son

dimensiones complementarias del tamaño del cliente, no redundancias espurias.




Figura 6.9: Matriz de correlación de las variables seleccionadas

6.3.2. Adecuación Muestral para PCA

Previo a la ejecución del Análisis de Componentes Principales, se verificó formalmente la adecuación estadística del espacio de características. La prueba de esfericidad de **Bartlett** ($\chi^2 = 4,394.58$, $gl = 91$, $p < 0.001$) rechazó la hipótesis nula de matriz identidad, confirmando la existencia de una estructura de correlación subyacente. Asimismo, el índice de adecuación muestral de **Kaiser-Meyer-Olkin** (KMO) arrojó un valor global de **0.716**, clasificado como *bueno* según la escala de Kaiser (1974). A nivel individual, doce de las catorce variables registraron $MSA_i \geq 0.55$, con un máximo de 0.956 en **CLV_Proxy**; únicamente **Porcentaje_Digital** ($MSA_i = 0.307$) y **CV_Volume** ($MSA_i = 0.476$) se ubicaron por debajo del umbral convencional de 0.50, sin comprometer la adecuación agregada del conjunto y respaldando la pertinencia de la matriz para la extracción de factores latentes.

6.3.3. Aplicación del Análisis de Componentes Principales

La convergencia de la evidencia estadística justifica formalmente la transición al Análisis de Componentes Principales (PCA) sobre la matriz $\mathbf{X}_{clean}$ estandarizada (Z-score, $\mu = 0$, $\sigma = 1$). Este enfoque proyecta a los clientes institucionales en un nuevo sistema de coordenadas ortogonales, absorbiendo la correlación natural del mercado en dimensiones latentes independientes.




Figura 6.10: Distribución de la varianza explicada/acumulada por componentes principales.




Figura 6.11: Representación bidimensional de las dos primeras componentes principales

6.3.4. Determinación del Número de Componentes a Retener

La literatura estadística multivariada ofrece múltiples criterios, no necesariamente convergentes, para la determinación del número óptimo de componentes principales a retener. Su aplicación conjunta -en lugar de la adopción acrítica de un único criterio- constituye la práctica recomendada para garantizar robustez metodológica Jolliffe (2002).

Criterio de Kaiser (*eigenvalue* > 1). Bajo la regla clásica de Kaiser (1960), se retienen aquellos componentes cuyo autovalor supera la unidad, dado que un componente con $\lambda < 1$ explica, en promedio, menos varianza que una única variable original estandarizada. La aplicación de este criterio identifica **4 componentes principales** ($\lambda_1 = 4.587$, $\lambda_2 = 2.812$, $\lambda_3 = 1.215$, $\lambda_4 = 1.111$) que explican conjuntamente el 69.46 % de la varianza total del

sistema. La frontera de decisión bajo este enfoque resulta nítida, toda vez que el quinto autovalor desciende a 0.930.

Criterio del codo (*Scree Test*). El examen visual de la pendiente en el gráfico de sedimentación (Figura 6.10), siguiendo los lineamientos de Cattell (1966), revela una caída pronunciada entre el primer y segundo componente ($\Delta\lambda_{1\rightarrow 2} = 1.775$), seguida de un descenso moderado hacia el tercero ($\Delta\lambda_{2\rightarrow 3} = 1.597$) y una marcada atenuación a partir de allí ($\Delta\lambda_{3\rightarrow 4} = 0.104$ y $\Delta\lambda_{4\rightarrow 5} = 0.181$). Esta morfología sugiere un punto de inflexión (*elbow*) ambiguo entre el segundo y el tercer componente, evidenciando una discrepancia metodológicamente relevante: mientras el criterio de Kaiser retiene 4 dimensiones, el examen visual favorece una solución más parsimoniosa de 2 o 3 componentes (los cuales representan el 52.85 % y 61.52 % de la varianza, respectivamente).

Regla de varianza acumulada. En el dominio de las ciencias sociales y de negocios, un rango de varianza acumulada entre el 70 % y el 80 % se considera metodológicamente adecuado (Hair et al., 2019). Bajo esta perspectiva, los datos ofrecen tres puntos de corte naturales: 4 componentes (69.46 %, situado marginalmente por debajo del límite inferior), 6 componentes (81.69 %, ubicado dentro de la zona objetivo) y 7 componentes (86.59 %, en el extremo superior del intervalo de referencia).

Consideración específica para PCA como insumo de *clustering*. Es fundamental destacar que el propósito de esta reducción dimensional no radica en la interpretación factorial autónoma, sino en la estructuración de un espacio geométrico óptimo para un algoritmo de agrupamiento no supervisado (*K*-Means). La literatura especializada en esta intersección metodológica (Ding & He, 2004; Yeung & Ruzzo, 2001) advierte que un truncamiento excesivamente restrictivo —guiado de forma exclusiva por la parsimonia del criterio del codo— puede suprimir dimensiones de varianza moderada o baja que resultan críticas para la separación geométrica de subgrupos genuinos pero minoritarios en la población. Por ello, se recomienda evaluar umbrales de varianza más flexibles (80–90 %) o retener la totalidad de las dimensiones con $\lambda > 1$.

Síntesis y decisión metodológica. La Tabla 6.3 sintetiza la convergencia y divergencia de los escenarios evaluados.

Criterio de Selección	Componentes a Retener	Varianza Acumulada
Kaiser ($\lambda > 1$)	4	69.46 %
Codo (<i>Scree Test</i>)	2–3	52.85 %–61.52 %
Varianza acumulada (umbral 70 %)	5	76.10 %
Varianza acumulada (umbral 80 %)	6	81.69 %
Varianza acumulada (umbral 85 %)	7	86.59 %

Cuadro 6.3: Comparación de criterios para la retención de componentes principales.

Ante la divergencia entre criterios, no se fijó a priori un único número de componentes; en su lugar, la decisión se trasladó a la etapa de validación empírica de *clustering*, descrita a

continuación.

6.3.5. Interpretación de la Estructura Latente Base

A fin de establecer una línea base de análisis, la Figura 6.12 presenta de forma gráfica la distribución de las cargas factoriales (*loadings*) correspondientes a la solución de 4 componentes seleccionada por el criterio de Kaiser. Para la interpretación sustantiva de cada dimensión, se retienen únicamente aquellas variables con una magnitud absoluta superior a 0.25, garantizando relevancia matemática y representatividad teórica:




Figura 6.12: Mapa de calor de cargas factoriales (*loadings*) de las variables conductuales de clientes.

Interpretación de los Componentes Principales

- **Componente 1 (32.76 % de varianza) — “Escala y Valor Económico del Cliente”:** Caracterizado por fuertes cargas negativas en `Count_of_Deals` (−0.415),

`Bank_Volume` (-0.399), `CLV_Proxy` (-0.371) y `Diversification_Score` (-0.314), en contraposición a una carga positiva en `Average_Spread_BPS` ($+0.359$). Este componente captura la dimensión fundamental de tamaño y relevancia comercial de la contraparte: los clientes con mayor volumen, frecuencia transaccional y valor de vida proyectado exhiben spreads significativamente más bajos —lo cual es consistente con la estructura de economías de escala de la mesa de dinero—, además de un portafolio cambiario más diversificado.

- **Componente 2 (20.09 % de varianza) — “Poder de Negociación y Patrón Temporal”:** Dominado por `Spread_vs_Benchmark` ($+0.442$), junto a contribuciones negativas de `HHI_Temporal` (-0.393), `USD_Flow_Direction` (-0.383), `Recency_Days` (-0.337) y `Spread_Price_Sensitivity` (-0.316). Este eje discrimina a las corporaciones que asumen un sobreprecio respecto al spread esperado según su escala (bajo poder de negociación) de aquellas con una actividad concentrada temporalmente y una alta sensibilidad al precio, mapeando un continuo entre relaciones comerciales cautivas y cuentas competitivas disputadas activamente en el mercado.
- **Componente 3 (8.68 % de varianza) — “Consistencia Operativa y Canal Comercial”:** Definido por cargas negativas en `CV_Volume` (-0.541) y `Porcentaje_Spot` (-0.451), frente a una carga positiva en `Share_of_Wallet` ($+0.472$). Este factor diferencia a los clientes caracterizados por tamaños de transacción altamente heterogéneos y un uso intensivo del mercado disponible inmediato (*spot*), de aquellos con patrones operativos homogéneos y una mayor porción de su billetera transaccional capturada por la institución.
- **Componente 4 (7.93 % de varianza) — “Adopción de Canal Digital”:** Dominado de forma casi exclusiva por `Porcentaje_Digital` ($+0.808$), con una influencia secundaria de `USD_Flow_Direction` (-0.306). Al constituirse como un eje prácticamente unidimensional, refleja que la digitalización operativa del cliente actúa como una fuente de variación independiente de las dimensiones de tamaño, rentabilidad o regularidad transaccional.

6.3.6. Validación Empírica del Espacio Geométrico y Selección de Clusters

Se evaluaron cuatro rutas alternativas hacia el espacio de agrupamiento: tres basadas en proyecciones del PCA (cuatro, cinco y seis componentes, correspondientes a los criterios de Kaiser y de varianza acumulada al 80 %) y una basada en el conjunto completo de las catorce variables originales estandarizadas. La Tabla 6.4 resume el mejor desempeño alcanzado por cada ruta a lo largo del rango evaluado ($k = 2$ a 8).

Los resultados muestran una jerarquía consistente y monótona entre rutas, replicada en los tres índices de validación: la ruta de cuatro componentes principales (criterio de Kaiser) superó sistemáticamente a las rutas de cinco y seis componentes, y estas, a su vez, superaron

Ruta	Dim.	Silueta (máx.)	Calinski-Harabasz (máx.)	Davies-Bouldin (mín.)
PCA – 4 componentes (Kaiser)	4	0.524	320.51	0.635
PCA – 5 componentes	5	0.480	264.33	0.700
PCA – 6 componentes (80 %)	6	0.448	236.61	0.741
Variables originales (directo)	14	0.376	167.17	0.937

Cuadro 6.4: Mejor desempeño de *clustering* alcanzado por cada ruta evaluada (todos los máximos/mínimos corresponden a $k = 3$, salvo Calinski-Harabasz en la ruta directa, óptimo en $k = 2$).

ampliamente a la ruta de agrupamiento directo sobre las catorce variables originales. La magnitud de la diferencia es sustancial: el coeficiente de silueta de la mejor ruta (0.524) casi duplica al de la ruta directa (0.376), y el índice de Calinski-Harabasz resulta prácticamente el doble (320.51 frente a 167.17). Este patrón es consistente con la expectativa teórica de que la proyección en componentes ortogonales de menor dimensionalidad mitiga la dilución de las distancias euclidianas característica de espacios de mayor dimensión, además de neutralizar la distorsión introducida por la colinealidad residual presente en las variables originales (notablemente, `Bank_Volume` y `Count_of_Deals`, con $VIF > 9$).

Asimismo, dentro de cada ruta se observó un patrón no monótono en función de k : el coeficiente de silueta alcanzó su máximo en $k = 3$ en las cuatro rutas, con un descenso pronunciado a partir de $k = 4$ (por ejemplo, de 0.524 en $k = 3$ a 0.403 en $k = 4$ para la ruta de cuatro componentes), señal característica de la fragmentación artificial de una estructura de tres grupos genuinos al forzar particiones adicionales.

Validación Complementaria del Número de Clústeres

El procedimiento de votación de `NbClust`, aplicado de manera independiente sobre cada una de las cuatro rutas evaluadas, identificó a $k = 3$ como el número óptimo de clústeres bajo la regla de mayoría en la **totalidad de las rutas**, con una proporción de votos a favor de $k = 3$ de entre el 62 % y el 70 % de los índices considerados en cada caso (13 a 14 votos sobre un total de 20 a 22 índices válidos por ruta). Las alternativas $k = 4$ y $k = 8$ recibieron apoyo minoritario y disperso en todas las rutas, sin representar una amenaza seria al consenso mayoritario. Este resultado constituye una cuarta línea de evidencia, independiente de los tres índices de validación interna reportados previamente, y resulta particularmente relevante por su robustez: el número óptimo de agrupaciones se mantuvo invariante frente a la representación geométrica del espacio de características (componentes principales de distinta dimensionalidad frente a variables originales), lo cual sugiere que la estructura de tres grupos constituye una propiedad estructural de los datos subyacentes y no un artefacto de la técnica de reducción dimensional empleada.

Decisión Final

La convergencia de las cuatro líneas de evidencia –coeficiente de silueta, índice de Calinski-Harabasz, índice de Davies-Bouldin y procedimiento de votación de NbClust– determinó la selección de la **ruta de Análisis de Componentes Principales con cuatro dimensiones (criterio de Kaiser)** y un número de **tres clústeres ($k = 3$)** como especificación final para la etapa de agrupamiento no supervisado. Esta decisión resuelve, con respaldo empírico directo, la divergencia observada entre los criterios teóricos de retención de componentes descrita en la Tabla 6.3: si bien la regla de varianza acumulada al 80 % sugería retener seis componentes, la evidencia de validación de *clustering* demuestra que la inclusión de los componentes quinto y sexto –que explican conjuntamente apenas un 12.23 % adicional de varianza– no solo no mejora, sino que deteriora sistemáticamente la calidad de la segmentación resultante, en línea con lo señalado por la literatura especializada en la intersección entre PCA y *clustering* respecto a que no toda varianza adicional retenida contribuye a la separación geométrica de grupos genuinos (Ding & He, 2004; Yeung & Ruzzo, 2001).




Figura 6.13: Panel comparativo de los 3 índices continuos + NbClust

Comparación de Algoritmos de Partición

La aplicación de los cuatro algoritmos sobre el espacio de cuatro componentes principales bajo la especificación inicial $k = 3$ produjo los resultados resumidos en la Tabla 6.5. K-Means, Ward Jerárquico y el método Híbrido arrojaron coeficientes de silueta similares y relativamente elevados (entre 0.520 y 0.524), con particiones prácticamente idénticas entre sí. PAM, en contraste, registró una silueta sustancialmente menor (0.406) bajo la misma especificación de k .

Método	Silueta	Tamaño C1	Tamaño C2	Tamaño C3
K-Means	0.5243	398	5	97
Ward Jerárquico	0.5196	100	395	5
Híbrido (Ward + K-Means)	0.5243	97	398	5
PAM	0.4055	97	307	96

Cuadro 6.5: Desempeño comparativo de los cuatro algoritmos bajo $k = 3$, espacio PCA-4 completo ($N = 500$).

El examen de los tamaños de clúster reveló un patrón sistemático: tanto K-Means como Ward Jerárquico y el método Híbrido aislaron consistentemente un tercer grupo de apenas **cinco observaciones** sobre un total de 500 (1.0 % de la muestra), mientras que PAM distribuyó dichas observaciones entre los otros dos grupos, produciendo una partición considerablemente más balanceada (97/307/96). La concordancia entre particiones, cuantificada mediante el Índice de Rand Ajustado (ARI) y la Información Mutua Ajustada (AMI), confirmó este patrón: K-Means, Ward e Híbrido presentaron concordancia casi perfecta entre sí ($\text{ARI} \in [0.973, 1.000]$), mientras que la concordancia de PAM con los tres métodos restantes fue sustancialmente menor ($\text{ARI} \approx 0.55$; $\text{AMI} \approx 0.51\text{--}0.54$). El ARI promedio entre la totalidad de pares de métodos se ubicó en 0.7685, superando el umbral de referencia de concordancia alta (≥ 0.70); no obstante, este promedio agregado ocultaba la discrepancia sistemática y dirigida del único algoritmo robusto a valores atípicos frente a los tres algoritmos sensibles a la suma de cuadrados, lo cual motivó una investigación diagnóstica adicional.

Diagnóstico de las Observaciones Discrepantes

El protocolo de diagnóstico aplicado sobre las cinco observaciones sistemáticamente aisladas por K-Means, Ward e Híbrido arrojó los siguientes hallazgos:

1. **Baja frecuencia transaccional.** Las cinco observaciones registraron entre 1 y 4 transacciones en el periodo anual completo, en contraste con una mediana muestral de 48 transacciones (Tabla 6.6). Dado que variables como `Spread_Price_Sensitivity` y `CV_Volume` se construyen como estadísticos de dispersión o correlación intra-cliente, su

estimación resulta intrínsecamente inestable bajo un número tan reducido de observaciones por cliente.

2. **Posición extrema en percentiles de tamaño económico.** Las cinco observaciones se ubicaron sistemáticamente entre los percentiles 0.2 % y 3.0 % de las distribuciones de *Bank_Volume* y *CLV_Proxy*, correspondiendo –en contraste con la hipótesis inicial de que se tratara de clientes de gran escala– a clientes del arquetipo *Transactional* con actividad prácticamente nula durante el periodo de observación, no a clientes corporativos de alto volumen.
3. **Confirmación mediante DBSCAN.** La aplicación del algoritmo DBSCAN sobre el espacio de características (radio de vecindad $\varepsilon = 1.0$, mínimo de puntos por vecindario $minPts = 5$, parámetro determinado mediante el gráfico de distancia al k -ésimo vecino más cercano) clasificó a las cinco observaciones en su totalidad como **ruido** (etiqueta de clúster 0), confirmando que no conforman una región de densidad propia, sino que se ubican de manera dispersa en zonas de baja densidad del espacio de características.

Cliente	N.º Trx.	Bank_Volume	Pctl. Volumen	CLV_Proxy	Pctl. CLV
CLI_118	1	22,605	0.2 %	352	0.2 %
CLI_214	2	409,038	2.6 %	3,323	2.8 %
CLI_260	2	481,529	3.0 %	707	0.8 %
CLI_271	1	65,344	0.4 %	453	0.6 %
CLI_390	4	248,200	1.0 %	2,153	1.6 %

Cuadro 6.6: Perfil de las cinco observaciones identificadas como ruido de densidad por DBSCAN.

La convergencia de estos tres elementos de evidencia –inestabilidad estadística esperada por baja frecuencia transaccional, posición atípica en percentiles, y clasificación formal como ruido por un algoritmo de densidad– llevó a la conclusión de que las cinco observaciones constituyen valores atípicos genuinos cuya presencia indujo la formación de un tercer agrupamiento espurio en los algoritmos sensibles a la suma de cuadrados, en lugar de reflejar un segmento de negocio sustantivo.

Re-evaluación de la Estructura tras la Exclusión de Valores Atípicos

Excluidas las cinco observaciones discrepantes ($N = 495$), se re-ejecutó íntegramente el protocolo de determinación del número de clústeres sobre la misma proyección de componentes principales previamente estimada. Los resultados se resumen en la Tabla 6.7.

A diferencia de la evaluación inicial –en la que cinco de seis criterios señalaban $k = 3$ y únicamente PAM discrepaba en favor de $k = 2$ –, la totalidad de los criterios convergió de manera unánime en $k = 2$ una vez excluidas las observaciones atípicas. La magnitud de la mejora

Criterio	k óptimo (con outliers)	k óptimo (sin outliers)
Silueta (K-Means)	3	2
Calinski-Harabasz	3	2
Davies-Bouldin	3	2
Salto de altura (Ward)	3	2
PAM	2	2
NbClust (mayoría)	3 (14/20 índices)	2 (11/24 índices)

Cuadro 6.7: Comparación del número óptimo de clústeres antes y después de la exclusión de valores atípicos.

en los índices de validación bajo $k = 2$ fue sustancial: el coeficiente de silueta se incrementó a 0.526 (K-Means) y 0.525 (PAM), valores prácticamente idénticos entre algoritmos antes divergentes, y el salto de altura en el dendrograma de Ward para la partición en dos grupos (33.42) más que duplicó al salto correspondiente a tres grupos en la evaluación original (19.47), evidenciando una discontinuidad estructural considerablemente más pronunciada.

Validación Externa mediante el Proceso Generador de Datos

Dado que la base de clientes se deriva de un proceso generador de datos sintético con dos arquetipos poblacionales conocidos a priori (*Corporate* y *Transactional*, en proporción 20%/80%, con parámetros de volumen y frecuencia transaccional sistemáticamente diferenciados), se contrastó la partición en dos clústeres obtenida tras la exclusión de valores atípicos contra dicha estructura verdadera. El Índice de Rand Ajustado entre ambas particiones alcanzó un valor de **0.9722**, indicando una concordancia casi perfecta (Tabla 6.8): el primer clúster coincidió con el arquetipo *Corporate* en 97 de 97 observaciones correctamente asignadas, mientras que el segundo clúster capturó 395 de 398 observaciones del arquetipo *Transactional*, con solamente tres observaciones de frontera clasificadas de manera distinta a su arquetipo de origen.

	Arquetipo Corporate	Arquetipo Transactional
Clúster 1	97	0
Clúster 2	3	395

Cuadro 6.8: Tabla de contingencia entre la partición $k = 2$ (sin valores atípicos) y el arquetipo verdadero del proceso generador de datos. ARI = 0.9722.

Como verificación complementaria, se examinó la estructura resultante al forzar una partición en tres grupos sobre el conjunto depurado de valores atípicos. Bajo dicha especificación, el coeficiente de silueta se redujo a 0.404 –sustancialmente inferior al 0.526 obtenido bajo $k = 2$ – y el tercer grupo emergente ($n = 80$) no constituyó un segmento independiente de la dimensión de escala, sino una subdivisión interna del clúster correspondiente al arquetipo




Figura 6.14: Algoritmo t-SNE para representación de los clientes en dos dimensiones

Transactional (80 de 395 observaciones de dicho arquetipo), sin evidencia de corresponder a un eje de comportamiento transversal a los arquetipos de tamaño.

6.4. Determinación del Agrupamiento

La convergencia de evidencia –validación interna unánime en $k = 2$ tras el diagnóstico y exclusión de valores atípicos, magnitud sustancialmente mayor del salto estructural en el dendrograma de Ward, y una validación externa con concordancia casi perfecta frente al proceso generador de datos subyacente ($ARI = 0.9722$)– determinó la adopción de $k = 2$ **clústeres sobre el espacio PCA-4, excluyendo las cinco observaciones de actividad transaccional mínima identificadas como ruido de densidad**, como especificación final para la caracterización sustantiva de los segmentos de clientes. Las cinco observaciones excluidas se documentan y reportan de manera independiente como un grupo residual de actividad atípica, sin incorporarse a la caracterización de los segmentos operativos principales.

Este resultado constituye, simultáneamente, una validación metodológica robusta del proceso generador de datos –la dimensión de mayor poder discriminante en el espacio de características corresponde, casi exactamente, a la diferenciación de arquetipos programada exógenamente– y un hallazgo sustantivo relevante: los ejes de comportamiento capturados

por los componentes principales segundo a cuarto (poder de negociación y patrón temporal, consistencia operativa y producto, adopción de canal digital) no generaron, en el presente conjunto de datos, una estructura de agrupamiento independiente y comparable en fuerza discriminante a la dimensión de escala económica. Esta evidencia sugiere que dichos ejes de comportamiento podrían constituir fuentes de heterogeneidad *dentro* de cada segmento de tamaño, antes que dimensiones ortogonales de segmentación per se, dirección que se explora descriptivamente en la caracterización de los segmentos resultantes.

6.4.1. Perfil Descriptivo de los Segmentos

La partición final comprende dos segmentos sobre una base de $N = 495$ clientes corporativos activos: el segmento **Corporate** ($n = 97$, 19.6 %) y el segmento **Transactional** ($n = 398$, 80.4 %). La Tabla 6.9 presenta las medianas de las variables clave por segmento y el resultado de la prueba de Mann-Whitney U con corrección de Bonferroni.

Dieciséis de las veinte variables perfiladas presentaron diferencias significativas tras la corrección de Bonferroni. Las dimensiones de escala exhiben las brechas más pronunciadas: el segmento Corporate registró una mediana de Bank_Volume de USD 363.9 millones frente a USD 4.7 millones en Transactional (razón de 77.8x) y una mediana de CLV_Proxy de USD 532,281 frente a USD 44,787 (razón de 11.9x). En términos de frecuencia, los clientes Corporate operaron en mediana 162 transacciones distribuidas en 120 días activos, frente a 39 transacciones en 40 días activos para Transactional.

Desde la perspectiva de precio, los clientes Corporate operaron con un spread comercial mediano de 47.0 puntos básicos, frente a 161.5 en Transactional (diferencia de 114.5 puntos básicos), con una desviación respecto al spread esperado por su escala (**Spread_vs_Benchmark**) de apenas 1.00 puntos básicos para Corporate y 29.89 para Transactional. Esta asimetría refleja el poder de negociación diferencial que el volumen transado confiere a los clientes de mayor escala en el mercado cambiario institucional.

El índice de concentración temporal HHI reveló que los Corporate distribuyen su actividad de forma casi perfectamente uniforme en el tiempo (mediana HHI= 0.010, próxima al mínimo teórico $\approx 1/\text{Active_Days}$), mientras que los Transactional muestran mayor concentración episódica (mediana HHI= 0.031). De manera coherente, la Recency_Days mediana de los Corporate fue de apenas 0.62 días, frente a 5.57 en Transactional.

El hallazgo más relevante para el entendimiento de la estructura de la relación bancaria es el de las cuatro variables sin diferencias significativas: **Porcentaje_Digital**, **Porcentaje_Spot**, **Porcentaje_COP** y **USD_Flow_Direction**. Corporate y Transactional son estadísticamente indistinguibles en sus preferencias de canal de ejecución, tipo de instrumento, par de monedas y dirección neta del flujo cambiario. La segmentación no refleja diferencias en la *naturale-*

Variable	Mediana Corporate	Mediana Transactional	Sig.
<i>Escala y valor económico</i>			
Bank_Volume (USD)	363,862,888	4,676,002	***
Count_of_Deals	162	39	***
Total_Revenue (USD)	alta	baja	***
Average_Deal_Size (USD)	2,328,266	136,130	***
CLV_Proxy (USD)	532,281	44,787	***
Active_Days	120	40	***
Revenue_per_Day (USD)	4,567	1,299	***
<i>Rentabilidad y precio</i>			
Average_Spread_BPS	47.0	161.5	***
Spread_vs_Benchmark	1.00	29.89	***
Spread_Price_Sensitivity	-0.856	-0.786	***
<i>Comportamiento temporal y operativo</i>			
Recency_Days	0.62	5.57	***
HHI_Temporal	0.010	0.031	***
Diversification_Score	1.481	0.993	***
Share_of_Wallet	0.958	0.871	***
CV_Volume	1.541	1.403	***
<i>Canal, producto y dirección de flujo</i>			
Porcentaje_Digital	0.793	0.799	ns
Porcentaje_Spot	0.951	0.950	ns
Porcentaje_COP	0.859	0.850	ns
USD_Flow_Direction	-0.236	-0.262	ns

Cuadro 6.9: Perfil comparativo de los segmentos por medianas. *** $p < 0.05$ con corrección de Bonferroni sobre 20 comparaciones simultáneas (prueba de Mann-Whitney U); ns: no significativo.

za de las operaciones —ambos perfiles operan predominantemente en el canal digital, en el par USD/COP y en el instrumento spot— sino en la *intensidad*, la *escala* y la *consistencia temporal* con que cada segmento lleva a cabo ese mismo tipo de transacciones.

6.4.2. Diagnóstico de Heterogeneidad Interna

Descomposición de la varianza por componente principal. La Tabla 6.10 presenta la descomposición de la suma de cuadrados total (SS_T) de cada componente principal en su componente entre grupos (SS_B) e intra-grupos (SS_W), siguiendo la identidad $S_T = S_B + S_W$ de las matrices de dispersión, con la media global como punto de referencia único en todos los cálculos para garantizar la no-negatividad de todos los términos (Johnson & Wichern, 2007).

Componente	SS_T	SS_B	SS_W	% Entre	% Dentro Corp.	% Dentro Trans.
PC1 Escala/Valor	2,004.71	1,474.32	530.39	73.5 %	8.2 %	18.2 %
PC2 Poder Neg. / Temp.	622.63	240.85	381.78	38.7 %	4.9 %	56.4 %
PC3 Consist. Operativa	560.36	5.29	555.07	0.9 %	6.8 %	92.3 %
PC4 Canal Digital	431.81	0.25	431.56	0.1 %	2.9 %	97.1 %

Cuadro 6.10: Descomposición de la suma de cuadrados total (SS_T) por componente principal. % Entre: fracción de SS_T atribuida a la separación entre segmentos. % Dentro Corp. y % Dentro Trans.: fracción de SS_T atribuida a la dispersión interna de cada segmento. La suma % Entre + % Dentro Corp. + % Dentro Trans. = 100 % (salvo redondeo). Verificación: $SS_B + SS_W = SS_T$ exacto en los cuatro componentes.

Los resultados revelan una estructura doble que constituye el hallazgo analítico central de esta sección. Por un lado, PC1 destina el 73.5 % de su varianza total a separar entre grupos, confirmando cuantitativamente que la dimensión de escala y valor económico es el eje dominante de la segmentación. Por otro lado, PC3 y PC4 destinan el 99.1 % y el 99.9 % de su varianza total a la heterogeneidad *intra-grupos*, concentrada abrumadoramente en el segmento Transaccional (92.3 % y 97.1 %, respectivamente). Esto implica que las dimensiones de consistencia operativa (PC3) y adopción de canal digital (PC4) no distinguen a Corporate de Transaccional en ninguna medida práctica, pero sí diferencian sustancialmente a los clientes Transaccional entre sí. PC2 ocupa una posición intermedia: contribuye con el 38.7 % de su varianza a la separación entre grupos y con el 56.4 % a la heterogeneidad interna de Transaccional, sugiriendo que el poder de negociación y el patrón temporal son dimensiones relevantes tanto para separar arquetipos como para diferenciar perfiles dentro del segmento mayoritario.

Silueta intra-segmento. La evaluación de la cohesión interna bajo sub-particiones de prueba reveló valores de silueta moderados: el segmento Corporate alcanzó una silueta promedio de 0.44 bajo $k = 3$ sub-grupos internos (9/44/44), y el segmento Transaccional de 0.37 bajo $k = 2$ sub-grupos (320/78). Estos valores, aunque no elevados en términos absolutos, superan el umbral mínimo de coherencia y son consistentes con la presencia de sub-agrupaciones potenciales más nítidas en Corporate que en Transaccional, donde la sub-estructura es más difusa.

Estadístico de Hopkins. El estadístico de Hopkins calculado de manera independiente para cada segmento confirmó la presencia de tendencia al agrupamiento en ambos casos: $H_{\text{Corporate}} = 0.667$ y $H_{\text{Transaccional}} = 0.802$, ambos superiores al umbral de referencia de 0.65

(Lawson & Jurs, 1990). El valor particularmente elevado en Transactional es coherente con los resultados de la descomposición de varianza: PC3 y PC4 acumulan el grueso de su varianza total dentro de este segmento, generando una heterogeneidad interna considerable en las dimensiones de comportamiento operativo y adopción tecnológica.

Los tres componentes del diagnóstico de heterogeneidad interna convergen en la misma conclusión: ambos segmentos, y en particular el segmento Transactional, contienen subestructura latente estadísticamente identificable. Esta evidencia delimita con precisión la línea de investigación futura más pertinente: la aplicación de un protocolo de sub-segmentación anidada dentro del segmento Transactional, operando exclusivamente sobre las dimensiones de comportamiento PC2–PC4 y neutralizando el efecto dominante de PC1 en la escala, podría revelar arquetipos conductuales diferenciados —por ejemplo, clientes de alta digitalización con actividad episódica frente a clientes de operativa regular y baja sensibilidad al precio— que habilitarían estrategias de relacionamiento más granulares que las derivadas de la segmentación de primer nivel aquí documentada.

7. Conclusiones

7.1. Implicaciones Gerenciales

Los resultados del proceso de segmentación analítica no constituyen únicamente un ejercicio de clasificación estadística: proporcionan una base empírica para rediseñar la arquitectura de relacionamiento comercial de la mesa de cambios corporativa en función de evidencia cuantitativa, superando la segmentación informal basada exclusivamente en el volumen nominal o en el criterio subjetivo del ejecutivo de ventas. A continuación se derivan las implicaciones accionables más directas para cada dimensión estratégica identificada en el análisis.

7.1.1. Estrategia de Precio y Gestión del Spread

El hallazgo más inmediatamente accionable del análisis es la brecha de 114.5 puntos básicos en el spread comercial mediano entre los segmentos Corporate (47.0 bps) y Transactional (161.5 bps). Esta diferencia es el resultado de políticas de precio discrecionales: el análisis de economías de escala documentado en la fase exploratoria demostró que existe una relación log-lineal robusta ($\hat{\beta}_1 = 0.6506$ en la especificación log-log) entre el volumen de la transacción y el ingreso generado, lo cual implica que el spread se comprime sistemáticamente a medida que aumenta el tamaño de la operación. El segmento Corporate opera en niveles de volumen donde esta compresión es pronunciada y esperada por el mercado; operar fuera de esa curva generaría pérdida del wallet del cliente.

La variable **Spread_vs_Benchmark** reveló que los clientes Corporate pagan en mediana solo 1.0 punto básico por encima del spread esperado por su escala, mientras los Transactional pagan 29.9 puntos básicos por encima. Esto implica dos recomendaciones de precio segmentadas:

- **Segmento Corporate:** Es usual que con algunos clientes se llegan a acuerdos de Spread dada la naturaleza del cliente o diferentes acuerdos con la casa matriz que también existen en otros países en los que opera con el determinado banco. Aunque

esta dinámica no se hizo explícita en el DGP sí se puede enmascarar con los resultados obtenidos y ser una de las explicaciones ante la diferencia en el Spread promedio con el otro segmento.

- **Segmento Transactional:** el spread promedio de 161.5 bps y una desviación de 29.9 bps respecto al esperado por escala sugieren que existe capacidad para capturar valor adicional en este segmento sin pérdida de wallet, siempre que el precio se acompañe de valor agregado en servicio y asesoría. La alta sensibilidad al precio (Spread_Price_Sensitivity más negativa en Corporate que en Transactional) indica que los Transactional son marginalmente menos elásticos al precio, lo que abre espacio para pricing diferencial por cliente según su patrón de recurrencia.

7.1.2. Estrategia de Canal y Digitalización

Uno de los hallazgos más contraintuitivos y estratégicamente relevantes del análisis es que `Porcentaje_Digital` no es estadísticamente significativo como variable diferenciadora entre segmentos ($p = 0.231$ sin corrección; no significativo con Bonferroni). Ambos segmentos operan con una proporción de transacciones digitales en torno al 79–80 %, sin diferencia sustantiva. Esto tiene una implicación directa para la estrategia de inversión tecnológica: la digitalización del canal de ejecución ya ha alcanzado un nivel de adopción transversal en la cartera de clientes corporativos, independientemente del tamaño del cliente.

En consecuencia, la inversión incremental del canal digital no debe justificarse con el argumento de “llevar a los clientes Transactional al canal digital” — ese proceso ya ocurrió. El argumento correcto es distinto: la digitalización debe profundizarse en la dimensión de *inteligencia de precio en tiempo real* para el segmento Corporate (algoritmos de pricing que ajusten el spread en función del volumen acumulado del día y de la posición de inventario de la mesa) y en la dimensión de *simplicidad y accesibilidad* para el segmento Transactional (reducción de fricción en el proceso de ejecución para clientes con baja frecuencia que pueden optar por canales bancarios alternativos ante cualquier complejidad operativa).

La dinámica que estos clientes manejan, adicional a lo que se demostró, es que ejecutan operaciones de volúmenes esporádicas y por medio de canales digitales, estos clientes al no requerir un acompañamiento como por ejemplo brindarles color de mercado, ni ejecutar productos de FX más sofisticados como Opciones, son clientes que se han ido automatizando en su mayoría y con los cuales se busca abarcar todo su wallet. Estos clientes no se consideran profesionales a la hora de negociar ni cuentan con una mesa de dinero especializada para operar por lo cual se aprovechan estas limitantes para cargar un spread en ocasiones por encima del valor de referencia.

Los canales digitales propios del banco se prestan para que unos cuantos clientes, a los que se les puede denominar como *Price Shoppers*, comparen precios con demás entidades y estás logren poner a competir a bancos con sus determinadas tasas. De manera adicional,

plataformas multibancarias como por ejemplo Bloomberg FXGO o Deutsche Börse 360T, son la opción preferida por los responsables de tesorería de las empresas y los gestores de activos. Permiten a los usuarios solicitar cotizaciones (RFQ) u obtener precios en tiempo real de varios bancos simultáneamente para garantizar la mejor ejecución y el cumplimiento normativo. Estas constituyen la competencia directa de las iniciativas digitales de un banco junto a las plataformas desarrolladas por los bancos tradicionales que operan divisas pero también por las fintechs / start-ups las cuales pese a enfocarse en un nicho diferente podrías llegar eventualmente a representar una amenaza para los bancos tradicionales dada su adopción a los medios digitales.

7.1.3. Gestión de la Recencia y Prevención de Abandono

La variable `Recency_Days` presentó diferencias significativas entre segmentos (mediana Corporate: 0.62 días; mediana Transactional: 5.57 días) y constituye un indicador de alerta temprana de riesgo de abandono cualitativamente distinto en cada segmento. Para los clientes Corporate, una `Recency_Days` superior a 5–7 días representa una anomalía estadística significativa (dado que su patrón habitual es de operación casi diaria) y debe activar un protocolo de contacto proactivo por parte del ejecutivo de cuenta. Para los clientes Transactional, la distribución de `Recency_Days` es más amplia por naturaleza, por lo que el umbral de alerta debe calibrarse de manera individual, comparando la recencia actual del cliente con su propio historial de frecuencia transaccional — no con el promedio del segmento.

Sin embargo, hay patrones temporales de clientes del segmento “Corporate”, como la operación mensual en el último tercio, que podrían afectar las métricas de recencia, sin tener en cuenta la fidelización o dinámicas financieras específicas.

El `CLV_Proxy` estimado incorpora precisamente este decaimiento exponencial por inactividad: $CLV \propto \exp(-Recency/365)$. Una mesa de cambios que monitoree activamente la evolución del CLV por cliente en el tiempo tiene, por tanto, un mecanismo cuantitativo de priorización de esfuerzo comercial de retención, más preciso que cualquier criterio basado en el volumen histórico absoluto.

7.1.4. Asignación de Capacidad Comercial

El análisis reveló que los 97 clientes Corporate (19.6 % de la cartera) generaron la mayor parte del ingreso de la mesa, mientras que los 398 clientes Transactional (80.4 %) aportan una fracción proporcionalmente menor pero con mayor spread unitario. Esta dualidad sugiere que el modelo de cobertura comercial óptimo no es el de un ejecutivo por segmento, sino el de una especialización funcional por tipo de interacción:

- **Ejecutivos de Relación (*Relationship Managers*):** dedicados al segmento Corporate, con capacidad analítica para estructurar operaciones complejas, negociar bandas de precio institucionales y hacer seguimiento a la posición de tesorería del cliente. La baja Recency y el alto HHI_Temporal de este segmento implican que la interacción es frecuente y técnicamente exigente.
- **Ejecutivos de Flujo (*Flow Traders / Sales Traders*):** orientados al segmento Transactional, con énfasis en velocidad de respuesta y eficiencia operativa. La naturaleza episódica de este segmento (HHI mediano de 0.031, Recency de 5.57 días) implica que la interacción es menos frecuente pero debe ser de alta calidad cuando ocurre, dado que cada contacto representa una fracción mayor del wallet anual del cliente.

Esta especialización es coherente con la segmentación empírica de ejecutivos documentada en el análisis exploratorio, donde Sales 1 concentró el 68 % de los clientes (mayoritariamente Transactional) con un ingreso promedio por operación de \$1,162, mientras que Sales 2–5 gestionaron carteras más pequeñas pero con ingresos promedio cercanos a \$3,000 por operación. Cabe la pena aclarar que este análisis no tuvo en cuenta la atribución de los sales por transacción sino la cobertura del portafolio asignado a cada sales.

7.1.5. Tratamiento del Grupo Residual de Actividad Atípica

Las cinco observaciones excluidas del proceso de segmentación (clientes con 1–4 transacciones en el año, percentil inferior al 3 % en volumen y CLV) no deben ignorarse desde una perspectiva comercial. Representan clientes que, por razones que el análisis cuantitativo no puede determinar sin información cualitativa adicional, tuvieron una actividad mínima en el periodo observado: pueden ser clientes nuevos en proceso de onboarding, clientes con necesidades cambiarias muy esporádicas (exportaciones o importaciones puntuales), o clientes que operan principalmente con otras instituciones y utilizan este banco como contraparte ocasional.

La recomendación gerencial es tratarlos como una **lista de desarrollo comercial prioritario**: su potencial de activación es alto (ya tienen relación formal con el banco), su costo de servicio marginal es bajo (ya están en el sistema), y su comportamiento futuro podría clasificarlos en cualquiera de los dos segmentos principales en función de cómo evolucione su actividad. Un protocolo de contacto con propuesta de valor específica (por ejemplo, acceso a pricing preferencial si superan un umbral de volumen mensual) tendría un costo de implementación mínimo y un potencial de retorno significativo.

7.2. Síntesis de Hallazgos

La presente investigación desarrolló un pipeline analítico integral para la segmentación de clientes corporativos de una mesa de cambios institucional, articulando desde la construcción del proceso generador de datos hasta la caracterización estadística de los segmentos resultantes y el diagnóstico de su estructura interna. Los hallazgos se organizan en tres niveles de contribución: metodológico, estadístico y sustantivo.

7.2.1. Contribuciones Metodológicas

El proceso de ingeniería de características demostró que la construcción acrítica de un vector de variables a partir de una base de datos transaccional agrupada introduce, de manera sistemática, dependencias algebraicas exactas entre variables que son matemáticamente indistinguibles de la colinealidad genuina pero que responden a una causa radicalmente distinta: no a la correlación empírica entre fenómenos económicos, sino a la identidad aritmética entre variables calculadas como transformaciones exactas unas de otras. La verificación empírica confirmó correlaciones de Pearson iguales a 1.000 entre cuatro pares de variables del vector original, con un determinante de la matriz de correlación tendente a cero y Factores de Inflación de la Varianza superiores a 18 en cuatro de las cinco variables del vector conductual propuesto inicialmente. Este hallazgo establece un precedente metodológico claro: en cualquier análisis multivariado aplicado a bases de datos derivadas de pipelines de agregación contable o financiera, el diagnóstico de dependencia algebraica por construcción debe preceder al diagnóstico de colinealidad estadística, dado que las herramientas convencionales de detección de multicolinealidad (VIF, determinante, `findCorrelation`) no distinguen entre ambas causas, y la corrección apropiada es diferente en cada caso.

El protocolo de selección de características resultante redujo el espacio de 31 variables originales a 14 dimensiones genuinamente independientes, verificadas mediante la convergencia de evidencia algebraica y empírica. Sobre este espacio depurado, el Análisis de Componentes Principales arrojó un índice KMO global de 0.716 —categoría buena según Kaiser (1974)— un resultado que contrasta directamente con el KMO máximo de 0.62 obtenido sobre el espacio original bajo cualquier configuración de depuración evaluada, evidenciando que el rediseño del proceso generador de datos y la depuración de dependencias algebraicas no solo es necesario para la validez del análisis sino que mejora sustancialmente su adecuación estadística.

La comparación sistemática de cuatro rutas hacia el espacio de agrupamiento —tres basadas en distintas especificaciones de componentes principales y una basada en variables originales estandarizadas— mediante tres índices de validación interna de naturaleza matemática complementaria (silueta, Calinski-Harabasz, Davies-Bouldin) y el procedimiento de votación de `NbClust` sobre aproximadamente 24 índices simultáneos constituyó un protocolo de decisión empírico que resolvió la divergencia entre los criterios teóricos de retención de componentes

(Kaiser sugería 4, la regla de varianza acumulada al 80 % sugería 6, el criterio del codo sugería 2–3). La evidencia convergió inequívocamente en la ruta de cuatro componentes como la que producía la segmentación de mayor calidad geométrica, con una silueta de 0.524 frente a 0.376 de la ruta directa sobre 14 variables — diferencia sustancial que valida empíricamente el beneficio de la reducción dimensional en este contexto específico.

El protocolo de diagnóstico de valores atípicos implementado —que articuló la inspección del perfil transaccional, la verificación de percentiles, la clasificación por DBSCAN y la comparación con un algoritmo robusto (PAM)— demostró que la discrepancia inicialmente observada entre los métodos sensibles a la suma de cuadrados (K-Means, Ward, Híbrido) y el método robusto (PAM) constituía evidencia diagnóstica valiosa, no ruido a ignorar. Las cinco observaciones discrepantes, identificadas formalmente como ruido de densidad por DBSCAN, eran clientes con 1–4 transacciones en el año cuyos estadísticos intra-cliente (correlación de Spearman, coeficiente de variación) son intrínsecamente inestables bajo tan bajo número de observaciones, generando un cluster espurio en los algoritmos basados en distancia al cuadrado. Esta secuencia —detección de discrepancia, investigación de causa, confirmación por método independiente, exclusión justificada y re-evaluación— constituye en sí misma una contribución metodológica al campo del análisis de conglomerados aplicado: operacionaliza la recomendación de Milligan (1980) y Kaufman y Rousseeuw (1990) de usar métodos robustos como diagnóstico de sensibilidad antes de confiar en los resultados de métodos basados en mínimos cuadrados.

7.2.2. Hallazgos Estadísticos

Tras la exclusión de los cinco valores atípicos confirmados, la totalidad de los criterios de determinación del número de clústeres evaluados —silueta, Calinski-Harabasz, Davies-Bouldin, salto de altura jerárquico de Ward y votación de `NbClust` sobre 24 índices— convergió de manera unánime en $k = 2$ sobre el espacio de cuatro componentes principales. Esta convergencia, que contrasta con el consenso parcialmente inducido por outliers observado en la evaluación inicial ($k = 3$ bajo 5 de 6 criterios), es estadísticamente más sólida precisamente porque elimina el componente espurio que artificialmente fragmentaba la estructura en tres grupos.

La validación cruzada entre los cuatro algoritmos de partición evaluados arrojó un Índice de Rand Ajustado promedio de 0.769 sobre la muestra completa, y de prácticamente 1.000 entre K-Means, Ward e Híbrido sobre la muestra depurada, confirmando que la estructura de dos grupos es robusta a la elección del algoritmo de partición. La validación externa mediante el contraste con el arquetipo verdadero del proceso generador de datos produjo un ARI de 0.9722 —concordancia casi perfecta— demostrando que el pipeline analítico completo (depuración de variables, reducción dimensional, agrupamiento no supervisado) fue capaz de recuperar la estructura poblacional subyacente sin haber accedido en ningún momento a las etiquetas de arquetipo durante el proceso de modelado.

La descomposición de la suma de cuadrados por componente principal dentro de cada segmento reveló una estructura doble de particular relevancia: PC1 (Escala y Valor Económico) destina el 73.5 % de su varianza total a separar entre grupos, confirmando cuantitativamente que la escala es el eje dominante de la segmentación; mientras que PC3 (Consistencia Operativa) y PC4 (Canal Digital) destinan el 99.1 % y el 99.9 % de su varianza, respectivamente, a la heterogeneidad interna de los segmentos, concentrada abrumadoramente en el segmento Transactional (92.3 % y 97.1 %). El estadístico de Hopkins calculado de forma independiente para cada segmento confirmó la presencia de sub-estructura latente en ambos casos ($H_{\text{Corporate}} = 0.667$; $H_{\text{Transactional}} = 0.802$), siendo particularmente pronunciada en el segmento mayoritario.

7.2.3. Hallazgos Sustantivos

La segmentación identificó dos perfiles de cliente corporativo cuya separación estadística es contundente en las dimensiones de escala, valor económico y consistencia operativa, pero estadísticamente indistinguible en las dimensiones de canal de ejecución, tipo de instrumento, par de monedas y dirección del flujo cambiario. El segmento Corporate ($n = 97$, 19.6 %) opera con volúmenes medianos de USD 363.9 millones, con una frecuencia mediana de 162 transacciones en 120 días activos, un spread mediano de 47.0 puntos básicos y una inactividad de apenas 0.62 días — un perfil de cliente de tesorería institucional con presencia permanente y alta sensibilidad al precio. El segmento Transactional ($n = 398$, 80.4 %) opera con volúmenes medianos de USD 4.7 millones, con 39 transacciones en 40 días activos, un spread mediano de 161.5 puntos básicos y una inactividad de 5.57 días — un perfil de cliente con necesidades cambiarias recurrentes pero de menor escala y mayor episodicidad.

El hallazgo de que las cuatro variables de naturaleza, canal y producto (`Porcentaje_Digital`, `textttPorcentaje_Spot`, `Porcentaje_COP` y `USD_Flow_Direction`) no presentaron diferencias estadísticamente significativas entre segmentos implica que la segmentación no refleja diferencias en *qué* hacen los clientes ni *cómo* lo ejecutan, sino en *cuánto*, *con qué frecuencia* y *con qué regularidad*. Este resultado tiene una implicación directa para la hipótesis de investigación que motivó el trabajo: la búsqueda de patrones de segmentación más allá del tamaño no encontró evidencia confirmatoria en el presente conjunto de datos, pero sí identificó las dimensiones específicas (PC3–PC4, con varianza concentrada dentro de Transactional) donde dicha heterogeneidad conductual existe potencialmente como sub-estructura latente, no como eje de separación de primer nivel.

7.3. Limitaciones

7.3.1. Limitaciones del Proceso Generador de Datos

La principal limitación del estudio reside en la estructura del proceso generador de datos sintético, que introdujo dos arquetipos poblacionales con diferencias explícitas y sustanciales en los parámetros de escala (volumen y frecuencia transaccional), mientras que las variables de comportamiento puro fueron simuladas con heterogeneidad dentro de cada arquetipo pero sin diferencias sistemáticas entre arquetipos. Esta decisión de diseño, que buscaba reproducir fielmente la estructura de una mesa de cambios real donde el tamaño del cliente es el principal factor diferenciador, determinó que el eje de escala dominara la partición de clustering por construcción. En consecuencia, el resultado de $k = 2$ con $\text{ARI} = 0.972$ respecto al arquetipo verdadero es simultáneamente una validación del pipeline analítico y una confirmación de que el DGP no fue suficientemente rico en heterogeneidad conductual inter-arquetipo para que emergieran segmentos de comportamiento independientes del tamaño.

Una segunda limitación del DGP es la calibración del término de ruido en las variables derivadas (`Share_of_Wallet`, `CLV_Proxy`), que en versiones anteriores del proceso generador generaba dependencias algebraicas casi exactas entre variables diseñadas para ser independientes. Aunque esta limitación fue identificada y corregida durante el análisis — constituyendo en sí misma uno de los hallazgos metodológicos del trabajo —, evidencia que la simulación de variables latentes de comportamiento con suficiente desacoplamiento de sus determinantes requiere una calibración más cuidadosa del ruido estocástico relativo a la magnitud de la señal. Del mismo modo se podría considerar abarcar un estudio más profundo de construcción de variables que permitan diversificar aún más la información auxiliar asociada a cada cliente.

7.3.2. Limitaciones del Análisis

El análisis de sub-segmentación interna se limitó al nivel de diagnóstico (silueta intra-segmento, descomposición de varianza, estadístico de Hopkins) sin ejecutar el protocolo formal de sub-segmentación anidada dentro del segmento Transactional. Si bien la evidencia de sub-estructura latente es estadísticamente clara ($H = 0.802$; PC3–PC4 concentrando el 92–97 % de su varianza dentro del segmento), la naturaleza y el contenido sustantivo de dichos sub-grupos permanecen sin caracterizar, limitando la granularidad de las recomendaciones comerciales derivables para el segmento mayoritario.

Un modelo de cluster adicional que no fue evaluado es el GMM — Modelos de Mezcla Gaussiana (Fraley & Raftery, 2002, Journal of the American Statistical Association; paquete `mclust`). Que a diferencia de K-Means (particiones duras, clusters esféricos), GMM asigna probabilidades de pertenencia y permite clusters elipsoidales de distinta forma y orientación

— más flexible si los grupos no son igual de "compactos" en el espacio de las componentes ortogonales y que podría representar una dirección de robustez adicional.

Finalmente, el análisis asume una segmentación estática basada en el comportamiento observado durante un año calendario completo. En un contexto operativo real, el comportamiento de los clientes evoluciona en función de ciclos económicos, cambios en la política cambiaria y variaciones en las necesidades de cobertura de cada empresa, lo cual haría necesario un esquema de segmentación dinámica con ventanas temporales móviles.

7.4. Recomendaciones

Los hallazgos del presente trabajo delimitan con precisión tres líneas de investigación futura de alta pertinencia, ordenadas por el alcance del esfuerzo analítico requerido.

Sub-segmentación anidada dentro del segmento Transactional. La evidencia estadística disponible —Hopkins= 0.802, PC3 y PC4 concentrando el 92.3% y 97.1% de su varianza dentro del segmento— justifica la aplicación de un protocolo completo de sub-segmentación anidada operando exclusivamente sobre las dimensiones de comportamiento PC2–PC4, neutralizando el efecto dominante de la escala (PC1). Este análisis podría revelar arquetipos conductuales diferenciados dentro del segmento Transactional (por ejemplo, clientes de alta digitalización con actividad episódica frente a clientes de operativa regular y baja sensibilidad al precio) que habilitarían estrategias de relacionamiento más granulares.

Enriquecimiento del proceso generador de datos. El rediseño del DGP para incorporar heterogeneidad conductual sistemática entre arquetipos —no solo dentro de ellos— permitiría probar de manera más directa la hipótesis de que existen patrones de segmentación basados en comportamiento que son ortogonales al tamaño del cliente. Esto requeriría introducir diferencias inter-arquetipo en los parámetros que gobiernan las variables de comportamiento puro (Porcentaje_Digital, HHI_Temporal, Spread_Price_Sensitivity), calibradas con referencia a datos reales de mesas de cambios institucionales o a la literatura empírica de microestructura de mercados cambiarios.

Segmentación dinámica con datos observacionales reales. La aplicación del pipeline analítico desarrollado en esta investigación sobre datos transaccionales reales de una mesa de cambios corporativa, con segmentación en ventanas temporales móviles de 90–180 días, permitiría evaluar la estabilidad temporal de los segmentos, identificar clientes en transición entre arquetipos y construir modelos predictivos de migración de segmento con horizonte de uno a dos trimestres. Esta extensión natural del trabajo requeriría, adicionalmente, la incorporación de variables macroeconómicas (tipo de cambio, diferenciales de tasas, volatilidad

implícita) como covariables del comportamiento transaccional, cerrando el círculo entre la microestructura del cliente y el entorno de mercado en el que opera. En el marco del acceso a datos reales, se debe tener en cuenta que hay información del cliente que es externa como el Wallet, el cuál proviene de el conocimiento del cliente, la comunicación con el pero a menos de una confirmación exacta de este, ese valor de no reflejar correctamente la capacidad operacional del cliente, añadiría sesgo a los análisis posteriores.

Hoja de Ruta Analítica para la Gestión Comercial

Los hallazgos del diagnóstico de heterogeneidad interna ($\text{Hopkins}_{\text{Transactional}} = 0.802$; PC3 y PC4 concentrando el 92.3 % y 97.1 % de su varianza dentro de Transactional) sugieren que la segmentación de primer nivel documentada en esta investigación es el punto de partida, no el destino final, de un programa de analytics comercial. La hoja de ruta analítica recomendada para la institución comprende tres horizontes:

1. **Corto plazo:** implementar el modelo de dos segmentos como base de la política de precios y asignación comercial, monitoreando mensualmente la evolución del CLV_Proxy y la Recency_Days de cada cliente como indicadores de alerta temprana.
2. **Mediano plazo:** ejecutar el protocolo de sub-segmentación anidada dentro del segmento Transactional, operando sobre las dimensiones de comportamiento PC2-PC4, para identificar sub-arquetipos conductuales que permitan personalizar la propuesta de valor dentro del segmento mayoritario.
3. **Largo plazo:** migrar hacia un modelo de segmentación dinámica que actualice la asignación de clientes a segmentos en función de su comportamiento observado en ventanas móviles de 90-180 días, en lugar de la segmentación estática basada en el año completo utilizada en esta investigación. Esto requeriría la implementación de un pipeline de datos en tiempo real alimentado desde el sistema transaccional de la mesa pero pudiendo considerar una componente de la actividad histórica en la formulación del modelo.

8. Apéndice

8.1. Metodología de Simulación y el Proceso Generador de Datos (DGP)

Dada la necesidad de construir una base de datos que cumpla la naturaleza de los registros transaccionales para operaciones de compra y venta de divisas en el mercado cambiario de Colombia, y considerando que se presentará una mezcla compleja de datos continuos, categóricos, temporales y con inflación de ceros, se aborda el proceso sin limitarse a una única distribución multivariada. El propósito es reflejar con precisión los comportamientos y principios de los datos transaccionales de un banco comercial con un fuerte volumen institucional.

Cabe aclarar que simular las variables de manera independiente destruiría las relaciones multivariadas inherentes al mercado. Por lo tanto, con el objetivo de acatar tanto las restricciones comerciales como los requerimientos estadísticos, se implementa un diseño estructural robusto.

Metodología: Simulación Jerárquica Condicional

El Proceso Generador de Datos (DGP) se ejecuta de forma secuencial en tres niveles de granularidad:

1. **Nivel 1 (Latente - Clientes):** Creación de $n = 500$ clientes, asignándoles rasgos macroeconómicos inherentes (arquetipos, propensiones y tasas operativas latentes).
2. **Nivel 2 (Transaccional - Base 1):** Simulación de un portafolio objetivo de aproximadamente 35,000 transacciones individuales condicionadas estrictamente a los rasgos de cada cliente.
3. **Nivel 3 (Cliente - Base 2):** Agregación analítica de la información transaccional a nivel de cliente (*Customer 360*).

1. Fase Latente: Conteo de Transacciones y Ajuste de Escala

Se asigna a cada cliente i un arquetipo operativo: un 20 % se define como corporativo institucional (*Corporate*) y el 80 % restante como comercial masivo (*Transactional*). Cada cliente posee una tasa transaccional latente λ_i proveniente de una distribución Gamma diferenciada por su segmento:

$$\lambda_i \sim \begin{cases} \text{Gamma}(\alpha = 5, \beta = 0.05) & \text{si } \text{Archetype}_i = \text{"Corporate"} \\ \text{Gamma}(\alpha = 2, \beta = 0.08) & \text{si } \text{Archetype}_i = \text{"Transactional"} \end{cases}$$

Para garantizar que el volumen total de transacciones simuladas converja con exactitud al objetivo institucional del banco ($N_{\text{target}} = 35,000$), se calcula y aplica un factor de ajuste determinístico sobre el vector latente:

$$\lambda_i^* = \lambda_i \cdot \left(\frac{N_{\text{target}}}{\sum_{k=1}^{500} \lambda_k} \right)$$

Finalmente, el número exacto de transacciones ejecutadas por el cliente i (N_i) se extrae de una distribución de Poisson condicionada:

$$N_i \mid \lambda_i^* \sim \text{Poisson}(\lambda_i^*)$$

Al integrar analíticamente la mezcla Poisson-Gamma, la distribución marginal de los conteos transaccionales modela una distribución Binomial Negativa, reflejando la sobredispersión típica de los datos reales.

2. Fase Transaccional (Base 1): Atributos y Reglas de Flujo

Temporalidad de Alta Precisión

Las fechas de las operaciones (t_{ij}) se muestrean exclusivamente sobre los días hábiles del año 2025 (excluyendo fines de semana). La probabilidad de ocurrencia conjunta está ponderada por el día de la semana y el tercil del mes:

$$P(t_{ij}) = P(\text{Día Semana}) \cdot P(\text{Tercil})$$

Donde se asigna un castigo por días festivos a los lunes ($P = 0.15$) frente al resto de la semana ($P_{\text{mar}} = 0.25, P_{\text{mié}} = 0.23, P_{\text{jue}} = 0.20, P_{\text{vie}} = 0.18$). Los terciles del mes capturan el incremento de actividad al cierre de período ($P_{\text{Early}} = 0.25, P_{\text{Mid}} = 0.35, P_{\text{Late}} = 0.40$).

Las horas específicas de ejecución se modelan mediante una distribución **Beta** escalada al rango operativo de la mesa de dinero (08:00 a 13:00 horas), concentrando la moda entre las 09:00 y las 11:00 horas:

$$\text{Hora}_{ij} = 08:00 + (5 \text{ horas}) \cdot \text{Beta}(2.5, 2.5)$$

Estructura de Canales, Productos y Liquidación

- **Canal** (Channel_{ij}): Variable categórica condicionada a la probabilidad latente del cliente, promediando un 80 % de adopción a través de canales digitales y un 20 % mediante telefonía o ejecución manual.
- **Producto** (Product_{ij}): El 95 % de las operaciones se cierran en modalidad *Spot* y el 5 % restante como contratos *Forward*.
- **Plazo de Liquidación** ($\text{Settlement_Lag}_{ij}$): Condicionado estrictamente al tipo de producto:

$$\text{Settlement_Lag}_{ij} \sim \begin{cases} \text{DiscretaU}(0, 2) \text{ días} & \text{si } \text{Product}_{ij} = \text{"Spot"} \\ \text{DiscretaU}(3, 180) \text{ días} & \text{si } \text{Product}_{ij} = \text{"Forward"} \end{cases}$$

Pipeline de Divisas y Direccionalidad del Flujo

La direccionalidad del flujo actúa como la variable conductora del pipeline de monedas. Se asigna una probabilidad fija donde el 50 % corresponde a ventas de dólares (*Sell USD*), el 40 % a compras de dólares (*Buy USD*), y el 10 % a operaciones internacionales sin intermediación de la moneda local (*Non-USD*).

La asignación de las monedas de compra (Buy_CCY) y venta (Sell_CCY) se acopla de manera estricta al par de divisas generado (Currency_Pair):

- **Flujos con USD:** El 95 % se asigna al par local USD/COP y el 5 % restante a los pares G10 EUR/USD o GBP/USD.
- **Flujos Non-USD:** Se distribuyen aleatoriamente en los pares cruzados del mercado internacional: EUR/GBP, EUR/JPY o GBP/JPY.

3. Modelación del Volumen, Spread y Estructura de Tasas

Volumen de Negociación (V_{ij})

Para garantizar la existencia de economías de escala y alcanzar las metas corporativas de negocio, el volumen de la transacción en equivalencia USD (V_{ij}) se extrae de una distribución **Lognormal**, forzando un piso mínimo comercial de \$1,001 USD mediante el uso de la función de cota inferior máx:

$$V_{ij} = \text{máx}(1001, \exp(Y_{ij})) \quad \text{donde } Y_{ij} \sim \mathcal{N}(\mu, \sigma^2 = 1.2^2)$$

Para reflejar el alto volumen demandado por la mesa corporativa, los parámetros de localización (μ) están calibrados en $\mu = 13.97$ para clientes institucionales corporativos y $\mu = 10.97$ para el segmento comercial transaccional.

Modelo Hurdle para Inflación de Ceros (*Zero-Spread*)

Para simular el beneficio de tasa cero otorgado a clientes de alto volumen o transacciones preferenciales, se utiliza un modelo de regresión logística inversa:

$$\text{logit}(P(S_{ij} = 0)) = -2.5 + 0.0000005 \cdot V_{ij} + 0.5 \cdot \mathbb{I}(\text{Channel}_{ij} = \text{"Digital"})$$

Se aplica un filtro de umbral empírico basado en el percentil 85 (`threshold_15`), forzando a que exactamente el 15 % de las operaciones posean un spread igual a cero ($S_{ij} = 0$).

Modelo OLS Log-Log para el Spread Comercial (S_{ij})

Para las transacciones que no pertenecen a la inflación de zeros, el spread cobrado en puntos básicos (Spread_BPS_{ij}) se deriva de un modelo microeconómico Log-Log con elasticidad negativa respecto al volumen. El intercepto se establece en 8.95 para proteger la rentabilidad global del banco ante el aumento masivo de volúmenes:

$$\ln(S_{ij}) = 8.95 - 0.35 \cdot \ln(V_{ij}) - 0.2 \cdot \mathbb{I}(\text{Channel}_{ij} = \text{"Digital"}) + \epsilon_{ij}$$

Donde $\epsilon_{ij} \sim \mathcal{N}(0, 0.3^2)$. Si la transacción fue marcada con *zero-spread*, $S_{ij} = 0$, de lo contrario $S_{ij} = \exp(\ln(S_{ij}))$. El ingreso generado se calcula de manera lineal como:

$$\text{USD_Revenue}_{ij} = V_{ij} \cdot \left(\frac{S_{ij}}{10,000} \right)$$

Consistencia de Tasa de Mercado ($Market_Rate$) y Tasa Cliente ($Deal_Rate$)

La tasa interbancaria de referencia ($Market_Rate_{ij}$) se genera dinámicamente según el par macroeconómico del año 2025:

- **USD/COP:** $M_{ij} \sim \mathcal{N}(4052.86, 120^2)$, acotado a $[3706.94 \leq M_{ij} \leq 4410.50]$.
- **EUR/USD:** $M_{ij} \sim \mathcal{N}(1.1306, 0.03^2)$.
- **GBP/USD:** $M_{ij} \sim \mathcal{N}(1.2850, 0.03^2)$.
- **Pares Cruzados:** Generados por arbitraje triangular explícito.

Posteriormente, la tasa final pactada con el cliente ($Deal_Rate_{ij}$) se construye inyectando el spread de forma direccional sobre la tasa intermedia:

$$Deal_Rate_{ij} = \begin{cases} M_{ij} \cdot \left(1 - \frac{S_{ij}}{10,000}\right) & \text{si Flow_Direction}_{ij} = \text{"Buy USD"} \\ M_{ij} \cdot \left(1 + \frac{S_{ij}}{10,000}\right) & \text{si Flow_Direction}_{ij} = \text{"Sell USD"} \end{cases}$$

Esta relación matemática asegura la identidad fundamental del spread:

$$S_{ij} = \frac{|Deal_Rate_{ij} - Market_Rate_{ij}|}{Market_Rate_{ij}} \cdot 10,000$$

4. Fase de Agregación Analítica del Cliente (Base 2 / Customer 360)

Métricas de Comportamiento, Consistencia y Riesgo

El diseño de las variables conductuales se fundamenta en métricas robustas de microestructura financiera. Un criterio central del proceso generador de datos es evitar dependencias algebraicas exactas entre variables, dado que la presencia de identidades contables en el espacio de características distorsionaría la estructura de covarianza, inflaría artificialmente el VIF y comprometería la validez de cualquier análisis de reducción de dimensionalidad o agrupamiento geométrico posterior. Bajo este principio, se definen las siguientes métricas:

- **Sensibilidad al Precio ($Spread_Price_Sensitivity_i$):** Mide la relación monotónica intra-cliente entre el spread cobrado y el volumen transado mediante el coeficiente

de correlación de **Spearman**. Esta métrica es preferida sobre el coeficiente de Pearson por su resistencia a la asimetría lognormal del volumen transaccional y a los valores atípicos inherentes a carteras corporativas:

$$\text{Spread_Price_Sensitivity}_i = \text{Corr}_{\text{Spearman}}(S_{ij}, V_{ij}), \quad N_i > 1; \quad 0 \text{ si } N_i = 1$$

- **Desviación de Precio (Spread_vs_Benchmark_i):** Cuantifica el exceso o descuento en puntos básicos cobrado al cliente respecto al nivel teórico de precio dictado por su economía de escala individual. Se construye a partir del modelo log-lineal estimado en el análisis exploratorio ($\hat{\beta}_0 = 8.95$, $\hat{\beta}_1 = -0.35$), el cual establece que el spread esperado decrece logarítmicamente con el volumen promedio de transacción:

$$\text{Spread_vs_Benchmark}_i = \bar{S}_i - \exp(8.95 - 0.35 \cdot \ln(\bar{V}_i))$$

donde $\bar{S}_i$ es el spread promedio del cliente y $\bar{V}_i$ su tamaño medio de transacción. A diferencia de la versión original del DGP, que restaba una mediana constante del portafolio generando una correlación exacta $r = 1$ con **Average_Spread_BPS**, esta formulación produce una variable con varianza genuinamente propia, dado que el spread esperado es una función no lineal del tamaño de transacción individual de cada cliente.

- **Direccionalidad del Flujo Cambiario (USD_Flow_Direction_i):** Índice de desequilibrio de órdenes (*order imbalance*) construido como el log-ratio del volumen total comprado frente al volumen total vendido en dólares. A diferencia de un índice de frecuencia, esta formulación captura el peso económico de la direccionalidad cambiaria del cliente en términos de monto transado, independientemente del número de operaciones:

$$\text{USD_Flow_Direction}_i = \ln \left(\frac{\sum_j V_{ij}^{\text{Buy}} + 1}{\sum_j V_{ij}^{\text{Sell}} + 1} \right)$$

Valores positivos indican clientes compradores netos de dólares (importadores, estructuradores de deuda); valores negativos, vendedores netos (exportadores, repatriadores de utilidades).

- **Concentración Temporal (HHI_Temporal_i):** Índice de Herfindahl-Hirschman aplicado sobre la distribución de transacciones en los días activos del cliente. Diferencia a clientes con actividad episódica (alta concentración en pocos días, $\text{HHI} \rightarrow 1$) de aquellos con operativa regular y distribuida a lo largo del año ($\text{HHI} \rightarrow 1/\text{Active_Days}_i$):

$$\text{HHI_Temporal}_i = \sum_d \left(\frac{n_{id}}{N_i} \right)^2$$

donde n_{id} es el número de transacciones del cliente i en el día d .

- **Heterogeneidad Transaccional (CV_Volume_i):** Coeficiente de variación intra-cliente del volumen transado. Complementa al tamaño medio de transacción (**Average_Deal_Size**)

de forma no redundante: dos clientes con el mismo promedio pueden diferir sustancialmente en consistencia (uno opera siempre montos similares; otro alterna entre operaciones pequeñas y megabloques):

$$CV_Volume_i = \frac{\sigma(V_{ij})}{\mu(V_{ij})}$$

- **Diversificación Cambiaria ($Diversification_Score_i$):** Entropía de Shannon calculada exclusivamente sobre los pares de divisas distintos de USD/COP operados por el cliente. Al excluir el par local —que representa el 85.6 % de las transacciones del portafolio y cuya presencia generaba una correlación espuria de $r = -0.901$ entre la entropía global y **Porcentaje_COP**— esta variable mide puramente la diversificación del portafolio *internacional* del cliente, con independencia de su exposición al peso colombiano:

$$Diversification_Score_i = - \sum_{k \neq \text{USD/COP}} p_{ik} \ln(p_{ik})$$

Un valor de cero indica un cliente que nunca operó pares internacionales; valores positivos reflejan portafolios con diversificación en múltiples cruces de monedas.

Proxy de Valor de Vida del Cliente (*CLV Proxy*)

El estimador predictivo del valor del cliente incorpora cuatro componentes: el valor económico histórico acumulado, un factor de decaimiento exponencial por recencia, una prima de retención institucional asociada a la digitalización de la relación, y un componente estocástico que refleja la incertidumbre inherente a la proyección del comportamiento futuro. A diferencia de la formulación original, que resultaba en una dependencia funcional exacta con **Total_Revenue** ($r = 1$), la inclusión del factor de incertidumbre γ_i desacopla el estimador de su determinante histórico, produciendo una correlación empírica de $r = 0.82$:

$$CLV_Proxy_i = Total_Revenue_i \cdot \exp\left(-\frac{Recency_Days_i}{365}\right) \cdot (1 + 0.3 \cdot Pct_Digital_i) \cdot \gamma_i$$

donde el choque de fricción comercial sigue una distribución Gamma con parámetros calibrados para un coeficiente de variación individual de aproximadamente 0.58: $\gamma_i \sim \text{Gamma}(\alpha = 3, \beta = 3)$.

Puntuación de Fidelidad, *Share of Wallet* y *Total Wallet*

Para estimar la cuota de mercado capturada de cada cliente, se modela un puntaje latente de atracción institucional (*sow_score*) sustentado en la digitalización, la concentración en

el mercado local, la actividad continua y la recencia. A diferencia del modelo original, esta formulación excluye **Average_Deal_Size** del lado derecho —que en la versión previa introducía circularidad algebraica con **Bank_Volume** y **Count_of_Deals**— y amplía el término de error estructural a $\sigma = 1.5$ (frente a $\sigma = 0.3$ en la versión original), con el fin de desacoplar el estimador de sus determinantes observados y producir correlaciones en el rango económicamente plausible de $[0.40, 0.65]$:

$$sow_score_i = 0.8 + 1.5 \cdot Pct_Digital_i + 1.2 \cdot Pct_COP_i + 0.8 \cdot z(Active_Days_i) - 0.6 \cdot z(Recency_Days_i) + \varepsilon_i$$

donde $\varepsilon_i \sim \mathcal{N}(0, 1.5^2)$ y $z(\cdot)$ denota la estandarización Z-score de la variable correspondiente. La transformación logística acotada convierte el puntaje en una participación de mercado estimada:

$$SoW_i = 0.20 + \frac{0.98 - 0.20}{1 + \exp(-sow_score_i)}$$

El tamaño inferido de la tesorería cambiaria anual del cliente se obtiene como:

$$Total_Wallet_i = \frac{Bank_Volume_i}{SoW_i}$$

Reglas de Negocio Estructurales y Validación del Portafolio

- **Asignación Comercial (Sales):** Se definen 5 ejecutivos de ventas. El 68 % de los clientes (340 empresas de arquetipo transaccional) se asignan estrictamente a la cartera de *Sales 1*. Los 160 clientes corporativos restantes se distribuyen aleatoriamente entre los ejecutivos *Sales 2* al *Sales 5*. Esta estructura calibra la distribución de ingresos por ejecutivo entre el 15 % y el 25 % del ingreso total de la mesa.
- **Convergencia de Metas y Dualidad de Margen:** El proceso generador de datos está calibrado estructuralmente para estabilizar un volumen promedio mensual de \$3.5 millones de USD y un ingreso mensual de \$6.7 millones de USD. La fuerte estructura de economías de escala produce un **Spread Promedio Ponderado por Volumen (VWAS) global de 19.14 BPS**, divergente de la media aritmética transaccional. Esta dualidad refleja el Efecto Pareto del sector cambiario.
- **Comportamiento Corporativo vs. Transaccional:** Los clientes corporativos diversifican su exposición operando con múltiples contrapartes bancarias, resultando en un *SoW* moderado (rango 30 %–60 %). Los clientes transaccionales concentran su flujo en la plataforma digital, capturando un *SoW* alto (rango 70 %–98 %).

8.2. Diccionario de Variables

Tabla de Datos Transaccionales (**base_transaccional**)

Esta tabla documenta la granularidad operativa más profunda de la simulación, donde cada fila corresponde a una orden individual ejecutada por la mesa de dinero del banco.

<i>Variable</i>	Descripción
<i>Deal_Number</i>	Identificador único secuencial de la transacción de divisas
<i>Deal_Date</i>	Fecha y hora exacta de ejecución de la operación fiscal 2025
<i>Client_Name</i>	Nombre o razón social de la empresa contraparte
<i>Client_ID</i>	Código de identificación único del cliente
<i>Sales_ID</i>	Identificador del ejecutivo de ventas asignado a la cuenta
<i>Channel</i>	Canal de negociación empleado (Digital o Manual)
<i>Product</i>	Tipo de instrumento financiero operado (Spot o Forward)
<i>Settlement_Lag</i>	Días de rezago para la liquidación física de los fondos
<i>USD_Revenue</i>	Ingreso total generado por la transacción expresado en USD
<i>USD_Volume</i>	Monto total de la operación en su equivalencia a dólares americanos
<i>Spread_BPS</i>	Margen comercial aplicado a la operación medido en puntos básicos
<i>Buy_CCY</i>	Divisa comprada por el cliente en la transacción
<i>Sell_CCY</i>	Divisa vendida por el cliente en la transacción
<i>Market_Rate</i>	Tasa de cambio interbancaria de referencia al momento del cierre
<i>Deal_Rate</i>	Tasa de cambio final pactada con el cliente (incluye spread)
<i>Flow_Direction</i>	Direccionalidad del flujo desde la óptica de dólares (Buy USD / Sell USD)
<i>Currency_Pair</i>	Par de divisas transado en los mercados financieros internacionales

Cuadro 8.1: Diccionario de variables para el registro histórico transaccional (**base_transaccional**)

Tabla de Parámetros de Clientes (**clientes_df**)

Esta estructura modela la capa latente y los parámetros iniciales del Proceso Generador de Datos (DGP) para cada uno de los 500 clientes del portafolio del banco.

Variable	Descripción
<i>Client_ID</i>	Código único de identificación asignado a la empresa
<i>Client_Name</i>	Razón social de la firma corporativa
<i>Archetype</i>	Segmentación estratégica del cliente (Corporate o Transactional)
<i>Sales_ID</i>	Asignación estructural del vendedor o mesa comercial dueña del cliente
<i>lambda_deals</i>	Tasa esperada latente de transacciones asignada al cliente
<i>prob_digital</i>	Propensión intrínseca del cliente a transar por canales electrónicos
<i>base_vol_meanlog</i>	Parámetro de localización estructural (μ) para la escala del volumen
<i>Target_Deals</i>	Conteo definitivo de transacciones a generar para el cliente en el año

Cuadro 8.2: Especificación de parámetros base y atributos latentes de los clientes (`clientes_df`)

Tabla Analítica Integral del Cliente (**base_clientes** - **Customer 360**)

Esta tabla representa el cubo de datos consolidado a nivel de cliente. Recopila las métricas de negocio agregadas y derivadas a partir del comportamiento conductual en el mercado cambiario.

Cuadro 8.3: Métricas analíticas avanzadas e indicadores agregados de la base de clientes (`base_clientes`)

Variable	Descripción
<i>Client_ID</i>	Código identificador único del cliente corporativo
<i>Client_Name</i>	Nombre corporativo o razón social de la contraparte
<i>Sales_ID</i>	Identificador del ejecutivo a cargo de la relación comercial
<i>Count_of_Deals</i>	Número de transacciones totales ejecutadas en el período anual
<i>Bank_Volume</i>	Volumen total transado con el banco en equivalencia USD
<i>Total_Revenue</i>	Margen de ingresos netos históricos aportados a la mesa FX (USD). Excluido del PCA por dependencia funcional con CLV_Proxy
<i>Average_Deal_Size</i>	Tamaño medio por transacción individual (USD). Excluido por relación algebraica exacta Bank_Volume/Count_of_Deals
<i>Average_Revenue</i>	Ingreso promedio por operación (USD). Excluido por relación exacta Total_Revenue/Count_of_Deals

Continued on next page

Cuadro 8.3: Métricas analíticas avanzadas e indicadores agregados de la base de clientes (base_clientes) (Continued)

<i>Variable</i>	<i>Descripción</i>
<i>Average_Spread_BPS</i>	Spread comercial medio cobrado en el portafolio (Puntos Básicos)
<i>Porcentaje_Spot</i>	Participación de productos de contado (<i>Spot</i>) sobre el total transado
<i>Porcentaje_Digital</i>	Participación operativa mediante canales electrónicos o digitales
<i>Porcentaje_COP</i>	Proporción de operaciones en el par USD/COP
<i>Revenue_Share_Pct</i>	Porcentaje de contribución al ingreso total del banco. Excluido por ser transformación afín de Total_Revenue
<i>Active_Days</i>	Días distintos con actividad registrada. Excluido por colinealidad empírica $r = 0.981$ con Count_of_Deals
<i>Ultima_Trx</i>	Marca de tiempo exacta de la última operación cerrada
<i>Recency_Days</i>	Días de inactividad desde la última operación hasta el cierre del período
<i>Pct_Buy_USD</i>	Proporción de operaciones de compra de USD. Excluido; USD_Flow_Direction captura su información de forma no redundante
<i>Pct_Sell_USD</i>	Proporción de operaciones de venta de USD. Excluido por suma cero con Pct_Buy_USD y Pct_NonUSD
<i>Pct_NonUSD</i>	Proporción de transacciones en pares de divisas sin USD/COP
<i>Spread_Price_Sensitivity</i>	Correlación de Spearman intra-cliente entre el spread y el volumen. Mide la elasticidad-precio individual del cliente (sustituye la versión Pearson de v1.0)
<i>spread_esperado</i>	Spread teórico de referencia: $\exp(8.95 - 0.35 \cdot \ln(\bar{V}_i))$. Variable auxiliar de cálculo, no entra al PCA
<i>Spread_vs_Benchmark</i>	Desviación del spread promedio del cliente frente al spread esperado por su economía de escala individual
<i>CV_Volume</i>	Coefficiente de variación del volumen intra-cliente. Mide heterogeneidad del tamaño de transacciones
<i>Revenue_per_Day</i>	Intensidad económica por día activo (USD). Excluido del PCA por colinealidad empírica $r = 0.937$ con Total_Revenue ; conservado como descriptor de perfilamiento
<i>HHI_Temporal</i>	Índice Herfindahl-Hirschman de concentración de transacciones en el tiempo

Continued on next page

Cuadro 8.3: Métricas analíticas avanzadas e indicadores agregados de la base de clientes (base_clientes) (Continued)

<i>Variable</i>	<i>Descripción</i>
<i>Diversification_Score</i>	Entropía de Shannon sobre pares de divisas no-COP. Mide diversificación del portafolio internacional del cliente
<i>USD_Flow_Direction</i>	Log-ratio del volumen comprado vs. vendido en USD. Mide la direccionalidad neta del flujo cambiario en términos de monto
<i>CLV_Proxy</i>	Estimador estocástico del valor de vida del cliente, ajustado por recencia, digitalización e incertidumbre de proyección individual
<i>sow_score</i>	Puntaje latente de fidelidad institucional. Variable auxiliar de cálculo, no entra al PCA
<i>Share_of_Wallet</i>	Estimación de la cuota del mercado cambiario del cliente capturada por el banco
<i>Total_Wallet</i>	Tamaño inferido de la tesorería cambiaria anual del cliente. Excluido del PCA por relación algebraica con Bank_Volume y Share_of_Wallet

Referencias

- Bonferroni, C. E. (1936). Teoria statistica delle classi e calcolo delle probabilità. *Pubblicazioni del R Istituto Superiore di Scienze Economiche e Commerciali di Firenze*, 8, 3-62.
- Caliński, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1), 1-27.
- Cattell, R. B. (1966). The scree test for the number of factors. *Multivariate Behavioral Research*, 1(2), 245-276.
- Charrad, M., Ghazzali, N., Boiteau, V., & Niknafs, A. (2014). NbClust: An R Package for Determining the Relevant Number of Clusters in a Data Set. *Journal of Statistical Software*, 61(6), 1-36.
- Cont, R. (2001). Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues. *Quantitative Finance*, 1(2), 223-236. <https://doi.org/10.1080/713665670>
- Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1*(2), 224-227.
- Ding, C., & He, X. (2004). K-means clustering via principal component analysis. *Proceedings of the Twenty-First International Conference on Machine Learning (ICML 2004)*, 225-232.
- Ester, M., Kriegl, H.-P., Sander, J., & Xu, X. (1996). A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, 226-231.
- Gastwirth, J. L. (1972). The Estimation of the Lorenz Curve and Gini Index. *The Review of Economics and Statistics*, 54(3), 306-316.
- Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8th). Cengage Learning.
- Hubert, L., & Arabie, P. (1985). Comparing Partitions. *Journal of Classification*, 2(1), 193-218. <https://doi.org/10.1007/BF01908075>
- Johnson, R. A., & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6th). Pearson Prentice Hall.
- Jolliffe, I. T. (2002). *Principal Component Analysis* (2nd). Springer-Verlag.
- Kaiser, H. F. (1960). The Application of Electronic Computers to Factor Analysis. *Educational and Psychological Measurement*, 20(1), 141-151. <https://doi.org/10.1177/001316446002000116>
- Kaiser, H. F. (1974). An Index of Factorial Simplicity. *Psychometrika*, 39(1), 31-36. <https://doi.org/10.1007/BF02291575>
- Kaufman, L., & Rousseeuw, P. J. (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*. John Wiley & Sons.

- Kennedy, P. (2008). *A Guide to Econometrics* (6th). Wiley-Blackwell.
- Kumar, V. (2008). *Customer Lifetime Value: The Path to Profitability*. Now Publishers.
- Lawson, R. G., & Jurs, P. C. (1990). New Index for Clustering Tendency and Its Application to Chemical Problems. *Journal of Chemical Information and Computer Sciences*, 30(1), 36-41. <https://doi.org/10.1021/ci00065a010>
- Lloyd, S. P. (1982). Least Squares Quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129-137. <https://doi.org/10.1109/TIT.1982.1056489>
- MacQueen, J. B. (1967). Some Methods for Classification and Analysis of Multivariate Observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281-297.
- Milligan, G. W. (1980). An Examination of the Effect of Six Types of Error Perturbation on Fifteen Clustering Algorithms. *Psychometrika*, 45(3), 325-342. <https://doi.org/10.1007/BF02293907>
- Milligan, G. W., & Cooper, M. C. (1985). An examination of procedures for determining the number of clusters in a data set. *Psychometrika*, 50(2), 159-179.
- Murtagh, F., & Legendre, P. (2014). Ward's Hierarchical Agglomerative Clustering Method: Which Algorithms Implement Ward's Criterion? *Journal of Classification*, 31(3), 274-295. <https://doi.org/10.1007/s00357-014-9161-z>
- Punj, G., & Stewart, D. W. (1983). Cluster Analysis in Marketing Research: Review and Suggestions for Application. *Journal of Marketing Research*, 20(2), 134-148. <https://doi.org/10.1177/002224378302000204>
- Rosenthal, R. (1994). Parametric measures of effect size. En H. Cooper & L. V. Hedges (Eds.), *The Handbook of Research Synthesis* (pp. 231-244). Russell Sage Foundation.
- Rousseeuw, P. J. (1987). Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- van der Maaten, L., & Hinton, G. (2008). Visualizing Data using t-SNE. *Journal of Machine Learning Research*, 9, 2579-2605.
- Ward, J. H. (1963). Hierarchical Grouping to Optimize an Objective Function. *Journal of the American Statistical Association*, 58(301), 236-244. <https://doi.org/10.1080/01621459.1963.10500845>
- Wilcoxon, F. (1945). Individual Comparisons by Ranking Methods. *Biometrics Bulletin*, 1(6), 80-83.
- Wriston, W. B. (1992). *The Twilight of Sovereignty: How the Information Revolution Is Transforming Our World*. Charles Scribner's Sons.
- Yeung, K. Y., & Ruzzo, W. L. (2001). Principal component analysis for clustering gene expression data. *Bioinformatics*, 17(4), 309-316.